BUSINESS INTELLIGENCE
CASO PRÁCTICO
GONZALO PRIETO LARA

1. Análisis de fuentes:

El archivo “IMF_Mystery_Shopping.csv” es una fuente estática .csv y contiene información detallada acerca de las encuestas realizadas. Se trata de un archivo plano .csv y su delimitador es “;”. Se ha utilizado Python para su análisis:

```
import pandas as pd
data_file = pd.read_csv('IMF_Mystery_Shopping.csv', sep = ';', encoding = 'latin-1')
```

```
data = pd.DataFrame(data_file)
data
```

	COD_LOC	NOMBRE_LOC	CP	POBLACION	OFICINA	PROVINCIA	COD_PROY	ID_EVALUACION	Fecha de ejecucion	COD_AUDITOR	RESULTADO	TITULO_CUESTIONA
0	12	MUCHAS BOIRO	15930	Boiro	910	A CORUÑA	0267_001	1938117	16/01/2014	R29407	0,9513	Nuevo cuestio Mu
1	17	MUCHAS CARBALLIÑO	32500	Carballiño	910	ORENSE	0267_001	1938118	10/01/2014	33466	0,8351	Nuevo cuestio Mu
2	21	MUCHAS BUEU	36930	Bueu	910	PONTEVEDRA	0267_001	1938119	10/01/2014	29100	0,8958	Nuevo cuestio Mu
3	31	MUCHAS VIGO I	36202	Vigo	910	PONTEVEDRA	0267_001	1938120	21/01/2014	34161	0,7625	Nuevo cuestio Mu
4	34	MUCHAS REDONDELA	36800	Redondela	910	PONTEVEDRA	0267_001	1938121	23/01/2014	34161	0,6069	Nuevo cuestio Mu
...	...	...	...	...	...	...	...	...	...	...	...	
32792	266	STAND - MEDIA MARKT BARAKALDO	48000	BARACALDO	905	VIZCAYA	0457_004	2016569	16/06/2014	A32801	1	CONSUMO IMA GRANDES SUPERFIC P2 (1
32793	266	STAND - MEDIA MARKT BARAKALDO	48000	BARACALDO	905	VIZCAYA	0457_004	2016570	16/06/2014	A32801	1	CONSUMO PROCES P2 (1
32794	324	GRUPO BONATEL, S.L.U.	12540	VILLAREAL	917	CASTELLON	0457_002	2016576	17/04/2014	31433	0,95	MYSTERY SHO FFQQ P1 (ABI
32795	161	AVEIRO	8000	AVEIRO	901	EXTRANJERO	0569_001	2016755	15/05/2014	33592	0,873	Prenatal My Shop
32796	161	AVEIRO	8000	AVEIRO	901	EXTRANJERO	0569_001	2016756	15/05/2014	33592	0,975	Prenatal Visual ti

32797 rows × 12 columns

La base de datos consta de **32. 797 filas** y **12 variables**. Estas últimas, son categorizadas de la siguiente manera:

```
data.dtypes
```

```
COD_LOC                object
NOMBRE_LOC             object
CP                      int64
POBLACION              object
OFICINA                object
PROVINCIA              object
COD_PROY               object
ID_EVALUACION           int64
Fecha de ejecucion     object
COD_AUDITOR            object
RESULTADO              object
TITULO_CUESTIONARIO    object
dtype: object
```

Las variables **CP** e **ID_EVALUACION** son reconocidas como **numéricas** mientras que el resto constan como **cadena de texto**.

A continuación, se describen detalladamente cada una de las variables:

1. COD_LOC:

```
data['COD_LOC'].value_counts()

COD_LOC
1       269
2       197
15      182
12      178
5       177
       ...
8131      1
8163      1
5860      1
5859      1
7415      1
Name: count, Length: 5646, dtype: int64
```

```
data['COD_LOC'].describe()

count     32797
unique     5646
top           1
freq        269
Name: COD_LOC, dtype: object
```

- Es el código de localización del centro al que se le ha realizado la encuesta.
- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos y alfanuméricos.
- La cardinalidad de esta variable es elevada, ya que hay una gran cantidad de valores únicos, en concreto 5.646. El valor que más se repite es "1", unas 269 veces.

2. NOMBRE_LOC:

```
data['NOMBRE_LOC'].value_counts()

NOMBRE_LOC
LUALBO, S.L                          872
Salesland                            690
Aventel                              519
GRUPCOM RETAIL,  S.L.                417
INTERNITY (AVENIR TELECOM S.A.)      346
                                    ...
holaMOBI Mogan                         1
holaMOBI Gijón                         1
holaMOBI Oviedo                        1
holaMOBI Colindres                     1
TOPA IRISH TAVERN                      1
Name: count, Length: 6702, dtype: int64
```

```
data['NOMBRE_LOC'].describe()

count           32797
unique           6702
top       LUALBO, S.L
freq              872
Name: NOMBRE_LOC, dtype: object
```

- Es el nombre de localización del centro al que se le ha realizado la encuesta.

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son alfanuméricos.

- La cardinalidad de esta variable es elevada ya que hay una gran cantidad de valores únicos, en concreto 6.702. El valor que más se repite es "LUALBO, S.L.", unas 872 veces.

3. CP:

```
data['CP'] = data['CP'].astype('object')
```

```
data['CP'].value_counts()
```

```
CP
28000    2321
8000      908
43840     233
8820      184
8028      153
         ...
17834       1
33947       1
12350       1
24411       1
29560       1
Name: count, Length: 1797, dtype: int64
```

```
data['CP'].describe()
```

```
count     32797
unique     1797
top       28000
freq       2321
Name: CP, dtype: int64
```

- Es el código postal.

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos.

- La cardinalidad de esta variable es elevada ya que hay una gran cantidad de valores únicos, en concreto 1.797. El valor que más se repite es "28000", unas 2321 veces.

4. POBLACION:

```
data['POBLACION'].value_counts()
```

```
POBLACION
MADRID                      1725
BARCELONA                   1288
Madrid                      1013
TE SIN FEE                   782
Barcelona                    745
                            ...
MONDOÑEDO (CASCO URBANO)       1
GUARDA, A                      1
PALMA, LA                      1
CREVILLENT                     1
Galdácano                      1
Name: count, Length: 2045, dtype: int64
```

```
data['POBLACION'].describe()
```

```
count      32716
unique      2045
top       MADRID
freq        1725
Name: POBLACION, dtype: object
```

- Es el nombre de la población.

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son alfanuméricos.

- La cardinalidad de esta variable es elevada ya que hay una gran cantidad de valores únicos, en concreto 2.045. El valor que más se repite es "MADRID", unas 1725 veces.

5. OFICINA:

```
data['OFICINA'].value_counts()

OFICINA
911    9221
901    7915
915    4469
917    2392
922    2171
910    1970
905    1554
908    1314
919     710
921     640
SGS     297
999      91
959      53
Name: count, dtype: int64
```

```
data['OFICINA'].describe()

count     32797
unique       13
top         911
freq       9221
Name: OFICINA, dtype: object
```

- Es el número de identificación de la oficina donde se realizó la encuesta.

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos.

- La cardinalidad de esta variable es baja ya que hay una muy reducida cantidad de valores únicos, en concreto 13. El valor que más se repite es "911", unas 9221 veces

6. PROVINCIA:

```python
data['PROVINCIA'].value_counts()
```

```
PROVINCIA
MADRID                    6663
BARCELONA                 5438
VALENCIA                  1879
ALICANTE                  1319
SEVILLA                    988
ASTURIAS                   941
A CORUÑA                   928
TARRAGONA                  874
MALAGA                     859
MURCIA                     793
PALMAS, LAS                716
SANTA CRUZ DE TENERIFE     648
CADIZ                      624
PONTEVEDRA                 607
VIZCAYA                    603
GIRONA                     596
BALEARES                   550
LLEIDA                     487
ZARAGOZA                   467
CORDOBA                    431
GRANADA                    397
CASTELLON                  362
EXTRANJERO                 358
GUIPUZCOA                  353
ALMERIA                    317
BADAJOZ                    311
NAVARRA                    309
VALLADOLID                 308
JAEN                       298
LEON                       280
CANTABRIA                  270
CIUDAD REAL                251
HUELVA                     238
ALBACETE                   233
TOLEDO                     230
ORENSE                     221
LUGO                       211
SALAMANCA                  171
ALAVA                      162
CACERES                    140
RIOJA, LA                  128
BURGOS                     128
HUESCA                     101
SEGOVIA                     92
AVILA                       85
CUENCA                      80
PALENCIA                    77
GUADALAJARA                 70
ZAMORA                      70
TERUEL                      46
SORIA                       33
MELILLA                     31
CEUTA                       25
Name: count, dtype: int64
```

```python
data['PROVINCIA'].describe()
```

```
count      32797
unique        53
top       MADRID
freq        6663
Name: PROVINCIA, dtype: object
```

- Es el nombre de la provincia en la que se realiza la encuesta.
- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son alfanuméricos.
- La cardinalidad de esta variable es baja ya que hay una reducida cantidad de valores únicos, en concreto 53. El valor que más se repite es "Madrid", unas 6663 veces.

7. COD_PROY:

```
data['COD_PROY'].value_counts()
```

```
COD_PROY
0457_003     9633
0457_002     2158
0457_004     1414
0010_001     1269
0111_001      911
             ...
ZOUK            1
PAPA LUNA       1
ROMANA          1
0053_1          1
465_002         1
Name: count, Length: 223, dtype: int64
```

```
data['COD_PROY'].describe()
```

```
count        32797
unique         223
top       0457_003
freq          9633
Name: COD_PROY, dtype: object
```

- Es el código de proyecto. Las encuestas responden a las características propias de cada proyecto.

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos y alfanuméricos.

- La cardinalidad de esta variable es media ya que hay una considerable cantidad de valores únicos, en concreto 223. El valor que más se repite es "0457_003", unas 9633 veces.

8. ID_EVALUACION:

```
data['ID_EVALUACION'] = data['ID_EVALUACION'].astype('object')
```

```
data.dtypes
```

```
COD_LOC                object
NOMBRE_LOC             object
CP                     object
POBLACION              object
OFICINA                object
PROVINCIA              object
COD_PROY               object
ID_EVALUACION          object
Fecha de ejecucion     object
COD_AUDITOR            object
RESULTADO              object
TITULO_CUESTIONARIO    object
dtype: object
```

```
data['ID_EVALUACION'].value_counts()
```

```
ID_EVALUACION
1938117    1
1989599    1
1990107    1
1990106    1
1990105    1
          ..
1968159    1
1968158    1
1968156    1
1968155    1
2016756    1
Name: count, Length: 32797, dtype: int64
```

```
data['ID_EVALUACION'].describe()
```

```
count       32797
unique      32797
top       1938117
freq            1
Name: ID_EVALUACION, dtype: int64
```

- Es el código de identificación de cada encuesta. Primeramente esta variable es reconocida por Panda(Python) como numérica y operable, y dado que no se pretende realizar operaciones numéricas con los valores de esta variable, su tipo es transformado a cadena de texto

- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos.

- La cardinalidad de esta variable es máxima, ya que todos los valores son únicos, es decir, un total de 32797.

9. Fecha de ejecucion:

```
data['Fecha de ejecucion'].value_counts()

Fecha de ejecucion
25/02/2014    520
19/02/2014    519
21/02/2014    503
20/02/2014    501
23/04/2014    497
             ...
29/06/2014      1
29/04/2013      1
04/01/2013      1
25/04/2013      1
01/01/2014      1
Name: count, Length: 188, dtype: int64
```

```
data['Fecha de ejecucion'].describe()

count          32796
unique           188
top       25/02/2014
freq             520
Name: Fecha de ejecucion, dtype: object
```

```
data['Fecha de ejecucion'] = pd.to_datetime(data['Fecha de ejecucion'])
data['Fecha de ejecucion'].agg(['min', 'max'])

min   1995-05-03
max   2014-12-12
Name: Fecha de ejecucion, dtype: datetime64[ns]
```

- Es la fecha en la que se realizó la encuesta.

- Esta es una variable cuantitativa temporal, dado que sigue un orden y permite operaciones de tiempo. Los valores son numéricos aunque se representen en un formato de barras.

- La cardinalidad de esta variable es media-baja, con 188 valores únicos. El valor que más se repite, unas 520 veces, es 25/02/2014.

- También se puede apreciar que la primera de estas encuestas se realizó en 1995 y la última en 2014.

10. COD_AUDITOR:

```
data['COD_AUDITOR'].value_counts()

COD_AUDITOR
citi_lop      782
R29530        467
A32809        412
R29502        410
a02401        380
             ...
66826           1
ELENALOPEZ      1
66675           1
34211           1
30870           1
Name: count, Length: 1169, dtype: int64
```

```
data['COD_AUDITOR'].describe()

count        32797
unique        1169
top       citi_lop
freq           782
Name: COD_AUDITOR, dtype: object
```

- El código del autor que realizó la encuesta.
- Esta es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Los valores son numéricos y alfanuméricos.
- La cardinalidad de esta variable es elevada ya que hay una gran cantidad de valores únicos, en concreto 1.169. El valor que más se repite es "citi_lop", unas 782 veces.

11. RESULTADO:

```
data['RESULTADO'].value_counts()

RESULTADO
1.0000    6174
0.0000    1743
0.0100     817
0.9500     795
0.9667     627
          ...
0.5279       1
0.6359       1
0.8726       1
0.5837       1
0.5206       1
Name: count, Length: 4205, dtype: int64
```

```
data['RESULTADO'].describe()

count    32797.000000
mean         0.797175
std          0.275862
min          0.000000
25%          0.765300
50%          0.900000
75%          0.970000
max          1.000000
Name: RESULTADO, dtype: float64
```

```
data['RESULTADO'].agg(['min', 'max'])

min    0.0
max    1.0
Name: RESULTADO, dtype: float64
```

- Es el resultado de la encuesta.
- Es una variable cuantitativa y sus valores se encuentran entre 0 y 1.

- La cardinalidad de esta variable es elevada ya que hay una gran cantidad de valores únicos.

11. TITULO_CUESTIONARIO

```
data['TITULO_CUESTIONARIO'].value_counts()

TITULO_CUESTIONARIO
MYSTERY SHOPPER ESPECIALISTA P6 (FEB_14)            979
MYSTERY SHOPPER ESPECIALISTA P1 (ABR_14)            936
MYSTERY SHOPPER ESPECIALISTA P5 (ENE_14)            859
Areas Compra Programada_Abril_2012                  847
RESUMEN ESPECIALISTAS PEC - P6 (13.14)              843
                                                   ...
Cuestionario TIGER                                    1
La Misión Check Restaurantes                          1
La Misión Check Servicio de Cafetería (El Olvido)     1
Pruebas del bug 4316                                  1
CONSUMO IMAGEN GRANDES SUPERFICIES - P2 (14.15)       1
Name: count, Length: 439, dtype: int64
```

```
data['TITULO_CUESTIONARIO'].describe()

count                                       32797
unique                                        439
top       MYSTERY SHOPPER ESPECIALISTA P6 (FEB_14)
freq                                          979
Name: TITULO_CUESTIONARIO, dtype: object
```

- Es el título de la encuesta.
- Es una variable cualitativa nominal, dado que no es cuantificable y no admite un criterio de orden. Sus valores son numéricos y alfanuméricos.
- La cardinalidad de esta variable es media, con 439 valores únicos. El valor que más se repite es "MYSTERY SHOPPER ESPECIALISTA (FEB_14)", unas 979 veces.

2. Análisis funcional y diagrama de arquitectura de flujo de datos.

El departamento antifraude de una compañía de mystery shopping desea hacer un seguimiento y analizar la información relativa a las encuestas que realizan sus clientes en los distintos centros.

DIAGRAMA DE FLUJO DE DATOS

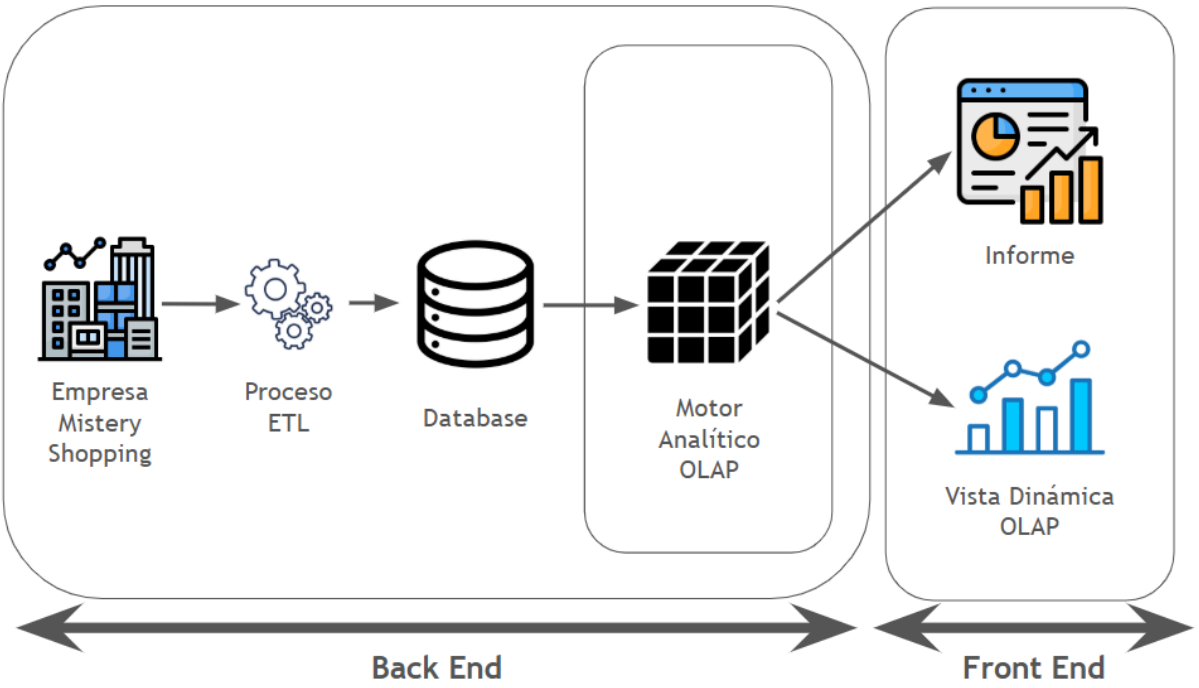

Back End:

- **Data Source:** La empresa Mistery Shopping realiza las encuestas y almacena los resultados en una fuente interna de la empresa.

- **ETL:** Extracción, transformación y carga de los datos en el Data Warehouse. Además, se filtran los datos, con el objeto de descartar valores nulos.

- **Data Warehouse:** Repositorio centralizado de datos para facilitar el análisis y la toma de decisiones del departamento antifraude de la empresa en cuestión.

- **Olap Cube:** Motor analítico OLAP para convertir los grandes volúmenes de datos en información estratégica, facilitando el análisis avanzado y la toma de decisiones en tiempo real.

Front End:

Un informe automatizado de los datos para consultar en detalle lo que la empresa requiera, y una vista dinámica OLAP para realizar los análisis de datos que sean necesarios, conforman el Front End del diagrama teniendo en cuenta las diferentes posibilidades de uso de los datos resultantes por parte de la empresa.

3. ¿Qué arquitectura de referencia se utilizaría?

Se utilizará una arquitectura clásica de Inteligencia de Negocio en tres capas, justificada así:

a) **Motivos:**

- Se requiere transformar datos operacionales en información analítica.
- Se trabaja principalmente con información histórica.
- No existe una necesidad actual de tiempo real, pero la arquitectura puede ampliarse si en el futuro se requiere.
- Garantiza escalabilidad, calidad del dato y separación de responsabilidades.

b) **Componentes de la arquitectura**

1. **Capa de Origen y Staging:**
    - Recepción del fichero IMF_Mystery_Shopping.csv.
    - Limpieza preliminar y estandarización.
    - Tablas:
        - ds_origen_ms (staging)
        - dv_datoslimpios_ms (clean layer)
2. **Capa de Data Warehouse**
    - Modelo en estrella con:
        - Tabla de hechos: h_resultados
        - Dimensiones: tiempo, ubicación, evaluador, cuestionario
    - Uso de claves surrogate para integridad y rendimiento.

3. **Capa de Presentación y Análisis (OLAP)**

    - Pentaho Server como plataforma BI.
    - Saiku como visor OLAP para consultas dinámicas.
    - Permite análisis antifraude, tendencias temporales, comparativas por localización, etc.

4. ¿Qué tecnología OLAP se utilizaría?

La tecnología OLAP más adecuada es ROLAP (Relational OLAP).

a) Justificación técnica

- Opera directamente sobre el Data Warehouse relacional (MySQL).
- Adecuado para consultas de alto detalle (granularidad fina).
- Escalable para grandes volúmenes de datos.

b) Ventajas frente a MOLAP

- No necesita duplicar datos en cubos preprocesados, lo cual requiere menor uso de disco.
- Mayor flexibilidad para consultas ad hoc demandadas por usuarios antifraude.
- No requiere procesos batch pesados ni precálculos complejos.
- Más adecuado cuando el modelo dimensional cambia o crece.

c) Compatibilidad

- Pentaho CE utiliza el motor OLAP Mondrian, que es nativamente ROLAP.
- Integración directa con Saiku Analytics.

5. Si se utiliza ROLAP, ¿cuál de estos dos modelos se ajustaría mejor: el modelo en estrella o el de copo de nieve?

El modelo en estrella:

a) **Menor complejidad estructural**

- Las dimensiones están directamente conectadas a la tabla de hechos.
- Menos tablas equivale a menos joins y mayor rendimiento.

b) **Consultas más rápidas**

- ROLAP ejecuta SQL sobre MySQL.
- Con estrella, las consultas generan menos JOINs, lo que reduce el tiempo de ejecución.

c) **Dataset con pocas dimensiones**

- 4 dimensiones principales.
- Cardinalidades moderadas.
- No justifica normalizar aún más (copo de nieve).

d) **Sobrecoste mínimo por desnormalización**

- Aunque las dimensiones duplican algunos atributos (por ejemplo PROVINCIA/CP/POBLACIÓN), el tamaño es muy pequeño comparado con la tabla de hechos.
- El almacenamiento extra es insignificante.

e) **Mejora la legibilidad y mantenimiento**

- Los usuarios antifraude y analistas consultan más fácilmente estructuras simples.
- El modelo estrella facilita:
    - Jerarquías
    - Drill-down
    - Agregaciones

6. Si se utiliza ROLAP, identificar y justificar si existe algún proceso de desnormalización de información que se deba realizar.

No se recomienda desnormalizar más las dimensiones:

a) **Ya existe redundancia natural en las dimensiones**

- Ejemplo: PROVINCIA >> POBLACIÓN >> CP
- Desnormalizar más (formar una única tabla gigante) solo duplicaría datos innecesariamente.

b) **Valores nulos detectados en origen**

- Algunos campos como ubicación o auditor tienen valores faltantes.
- Si se desnormaliza, estos nulls se arrastran y por tanto se generan estructuras menos consistentes.

c) **El modelo en estrella YA implica una desnormalización adecuada**

- El diseño en estrella **es en sí mismo una desnormalización controlada**:
  - Las dimensiones ya contienen atributos repetidos que no aparecen en varias tablas.
- Desnormalizar más rompería la integridad y claridad del modelo.

d) **Mejor integridad referencial**

- Dimensiones con Primary Key limpia.
- Tabla de hechos con solo Foreign Keys.
  - Esto simplifica el ETL y el motor OLAP.

e) **Mejor rendimiento OLAP**

- Mondrian (ROLAP) funciona mejor con:
  - Dimensiones pequeñas, compactas.
  - Un único join por dimensión.
- Desnormalizar más empeora tiempos de filtro y agregación.

7. Si se utiliza ROLAP, incluir un diseño conceptual a modo explicativo junto con un diagrama.

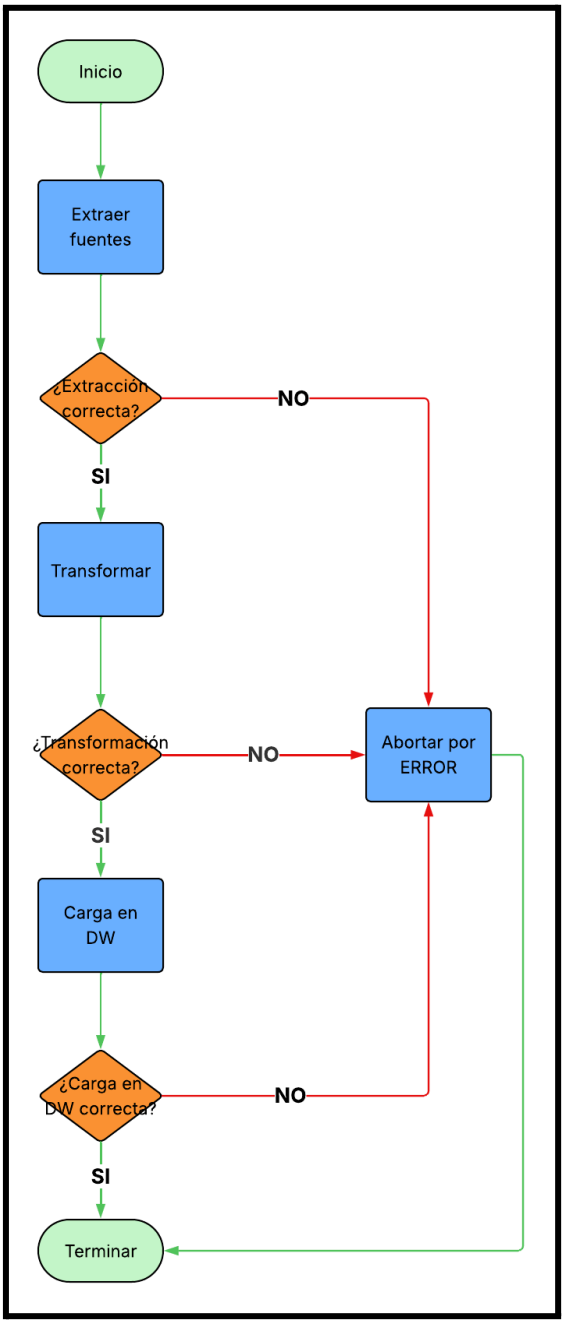

El proceso ETL sigue un flujo estándar de tres fases (Extracción, Transformación y Carga), incluyendo validaciones tras cada etapa y rutas alternativas para la gestión de errores.

8. Si se utiliza ROLAP, incluir un diseño modelo lógico.

El modelo lógico ROLAP se basa en un esquema en estrella compuesto por una tabla de hechos (h_resultados) y cuatro dimensiones (dim_tiempo_full, dim_ubicacion, dim_evaluador, dim_cuestionario). Cada dimensión dispone de una clave sustituta (id_dim_*) que actúa como PK (Primary Key) y se utiliza como FK (Foreign Key) en la tabla de hechos. Las relaciones son de tipo 1:N (uno a muchos) desde cada dimensión hacia la tabla de hechos, lo que permite analizar la métrica resultado según ejes temporales, geográficos, de evaluador y de cuestionario.

Tabla de hechos: h_resultados

- **Propósito:** almacenar cada evaluación realizada (hechos de negocio).
- **Estructura lógica:**
    - id_h_resultados (PK, BIGINT, surrogate key)
    - id_dim_tiempo (FK >> dim_tiempo_full.id_dim_tiempo)
    - id_dim_ubicacion (FK >> dim_ubicacion.id_dim_ubicacion)
    - id_dim_evaluador (FK >> dim_evaluador.id_dim_evaluador)
    - id_dim_cuestionario (FK >> dim_cuestionario.id_dim_cuestionario)
    - resultado (DECIMAL) >> medida principal
    - numero_cuestionarios
    - maximo_resultado
    - minimo_resultado

Dimensión tiempo: dim_tiempo_full

- **Propósito:** describir el eje temporal de las evaluaciones.
- **Estructura lógica:**
    - id_dim_tiempo (PK, BIGINT, surrogate key)
    - fecha (DATE)

    - anio (INT)
    - trimestre (INT)
    - mes (INT)
    - dia (INT)

- **Relación lógica:**
    - dim_tiempo_full.id_dim_tiempo <<>> h_resultados.id_dim_tiempo

Dimensión ubicación: dim_ubicacion

- **Propósito:** describir la localización del centro evaluado.
- **Estructura lógica:**
    - id_dim_ubicacion (PK, BIGINT, surrogate key)
    - cod_loc (VARCHAR) – código de localización
    - nombre_loc (VARCHAR) – nombre de localización
    - cp (INT / VARCHAR) – código postal
    - poblacion (VARCHAR)
    - provincia (VARCHAR)
    - cod_prov (INT) – código de provincia
- **Relación lógica:**
    - dim_ubicacion.id_dim_ubicacion <<>> h_resultados.id_dim_ubicacion

Dimensión evaluador: dim_evaluador

- **Propósito:** describir al auditor / evaluador que realiza la visita.
- **Estructura lógica:**
    - id_dim_evaluador (PK, BIGINT, surrogate key)

    - cod_auditor (VARCHAR) – identificador del auditor
    - oficina (VARCHAR) – oficina o delegación
- **Relación lógica:**
    - dim_evaluador.id_dim_evaluador <<>> h_resultados.id_dim_evaluador

Dimensión cuestionario: dim_cuestionario

- **Propósito:** describir el proyecto/cuestionario aplicado en la evaluación.
- **Estructura lógica:**
    - id_dim_cuestionario (PK, INT, surrogate key)
    - cod_proy (VARCHAR) – código de proyecto
    - titulo_cuestionario (VARCHAR)
    - id_evaluacion (VARCHAR) – identificador de la evaluación en origen
- **Relación lógica:**
    - dim_cuestionario.id_dim_cuestionario <<>> h_resultados.id_dim_cuestionario

9. Si se utiliza ROLAP, se debe incluir un diseño modelo físico.

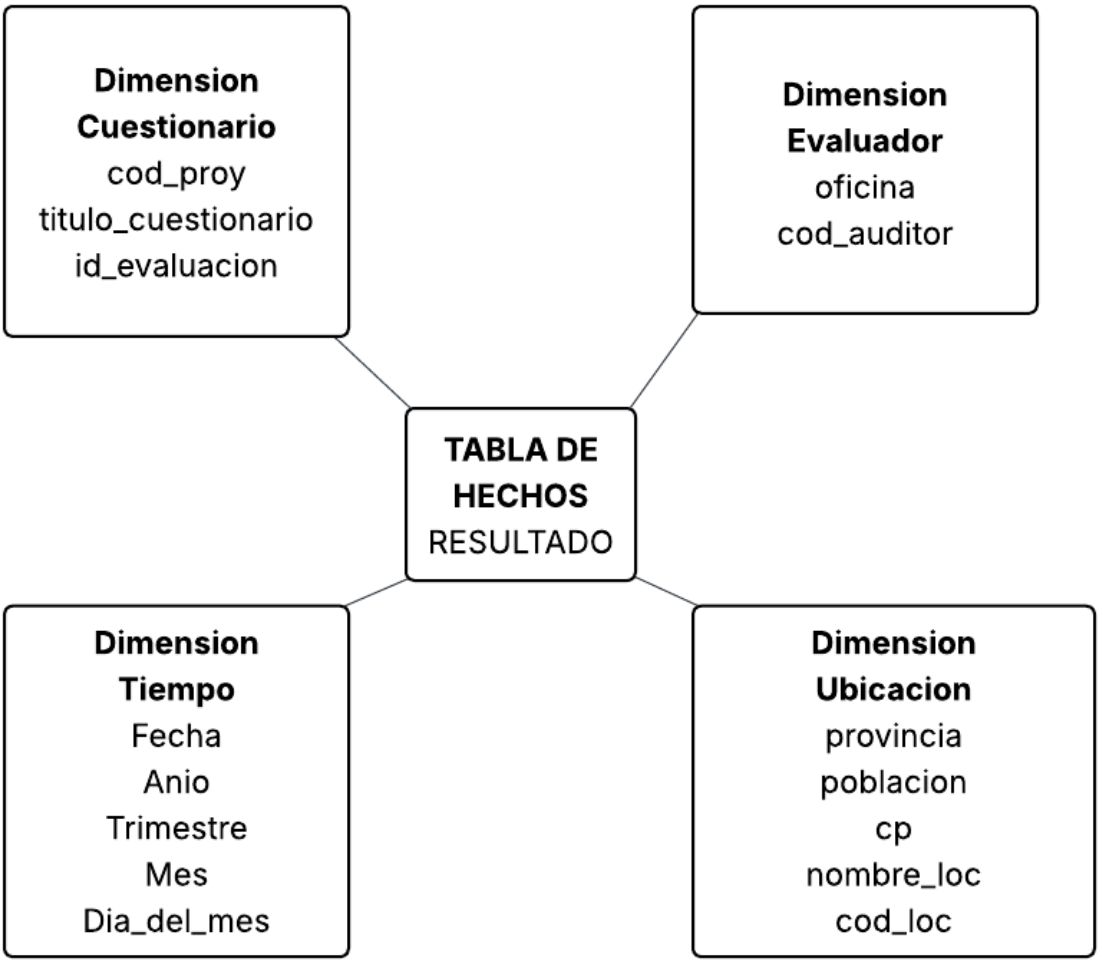

10. Realizar la implementación del proceso ETL para generar y poblar el modelo multidimensional diseñado en los apartados anteriores. Para ello, se partirá del job o trabajo global "Global_IMF.kjb"que se puede descargar desde la máquina virtual.

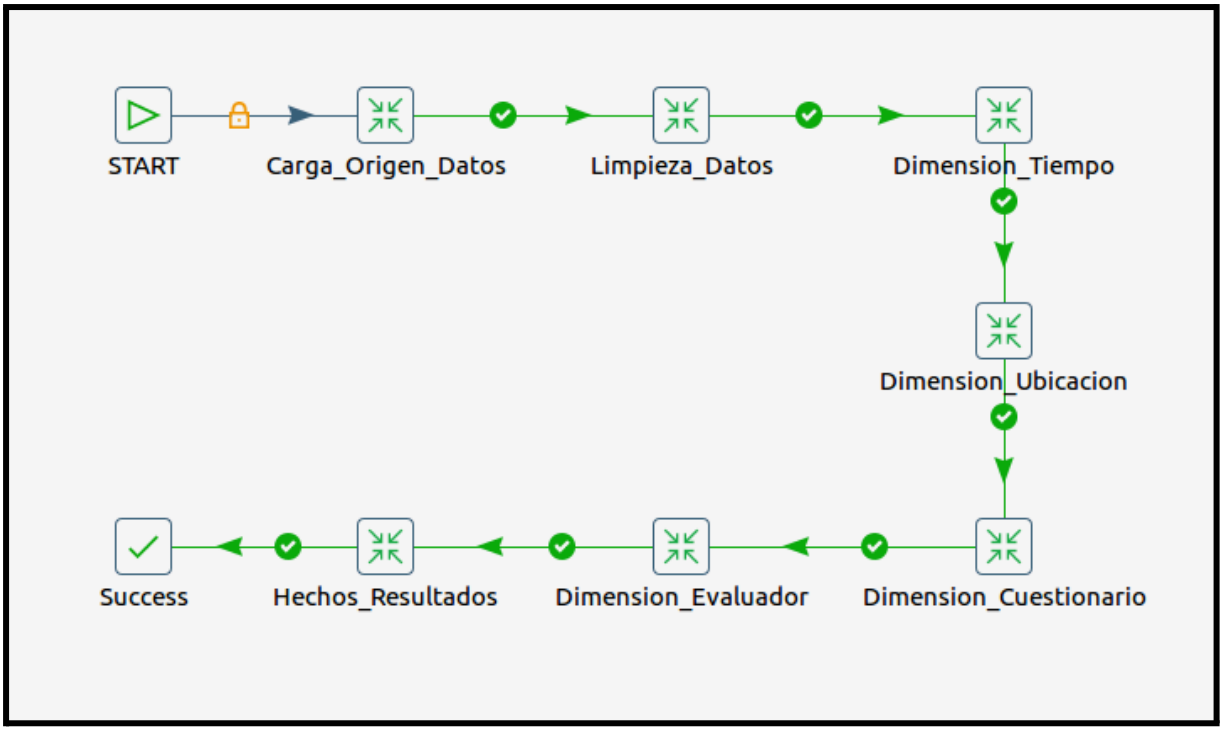

A continuación se presenta el modelo del proceso ETL siguiendo la arquitectura propuesta. Se parte del Job Global_IMF, estructurado en tres fases principales:

Extracción

Corresponde a la transformación Carga_Origen_Datos, cuya función es:

- Leer el archivo CSV original.
- Importar todos los registros.
- Aplicar una primera validación de formato y estructura.
  Si la extracción falla, el flujo se desvía al paso Abortar por ERROR.

Transformación

Corresponde a la transformación Limpieza_Datos, donde se realizan:

- Normalización de texto (espacios, mayúsculas, caracteres especiales).
- Sustitución de separadores decimales.
- Validación y filtrado de registros no válidos.

- Conversión de tipos (string → número, fecha, etc.).
  Si ocurre algún problema, se redirige igualmente a Abortar por ERROR.

Carga

Incluye todas las transformaciones:

- Dimension_Ubicacion
- Dimension_Evaluador
- Dimension_Cuestionario
- Dimension_Tiempo
- Hechos_Resultados

En ellas se:

- Insertan los valores únicos en cada dimensión.
- Inserta la tabla de hechos vinculando los ID de las dimensiones correspondientes.
  Si la carga falla, también se aborta el proceso.

Fin del proceso

Si las 3 fases (extracción, transformación y carga) se completan correctamente el Job finaliza en el nodo Success.

Cada uno de estos pasos ejecuta un job independiente, descrito a continuación:

Carga_Origen_Datos.ktr

Esta transformación se compone de dos pasos:

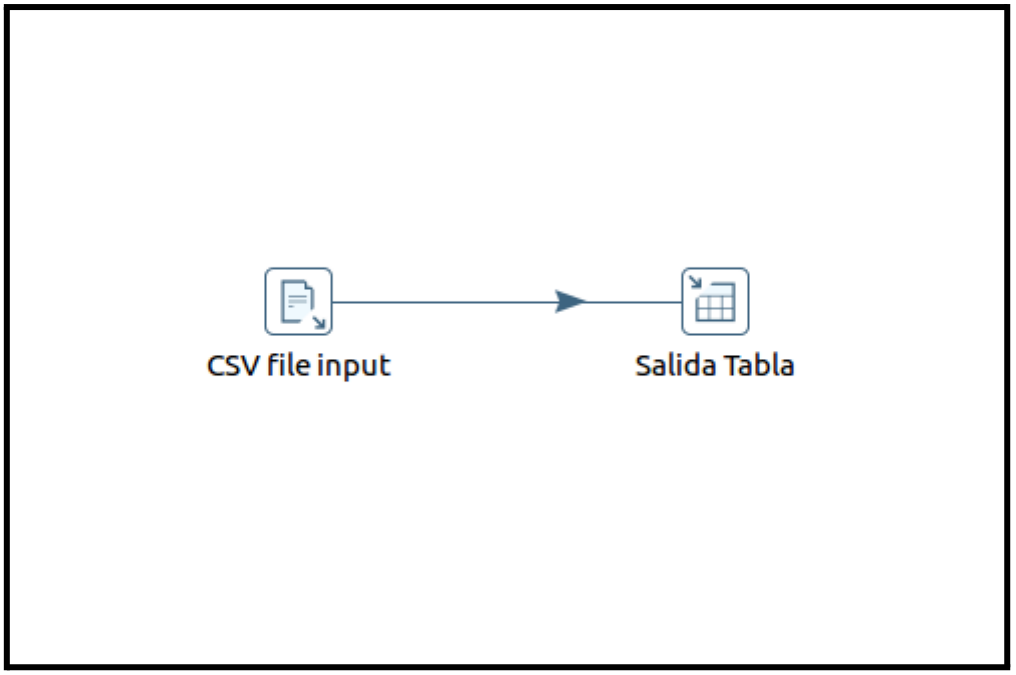

1. **CSV file input:**

    a. Filename: **IMF_Mystery_Shopping.csv**.

    b. Delimiter: “**;**”.

    c. File encoding: **UTF-8**.

    d. Traer Campos y Previsualizar.

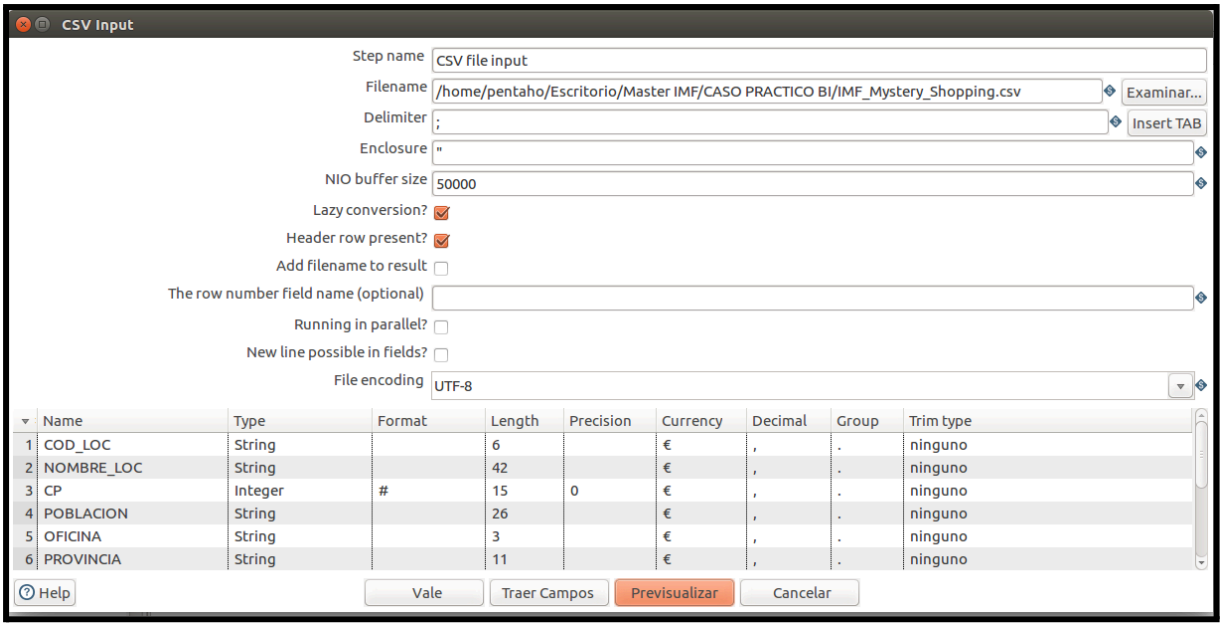

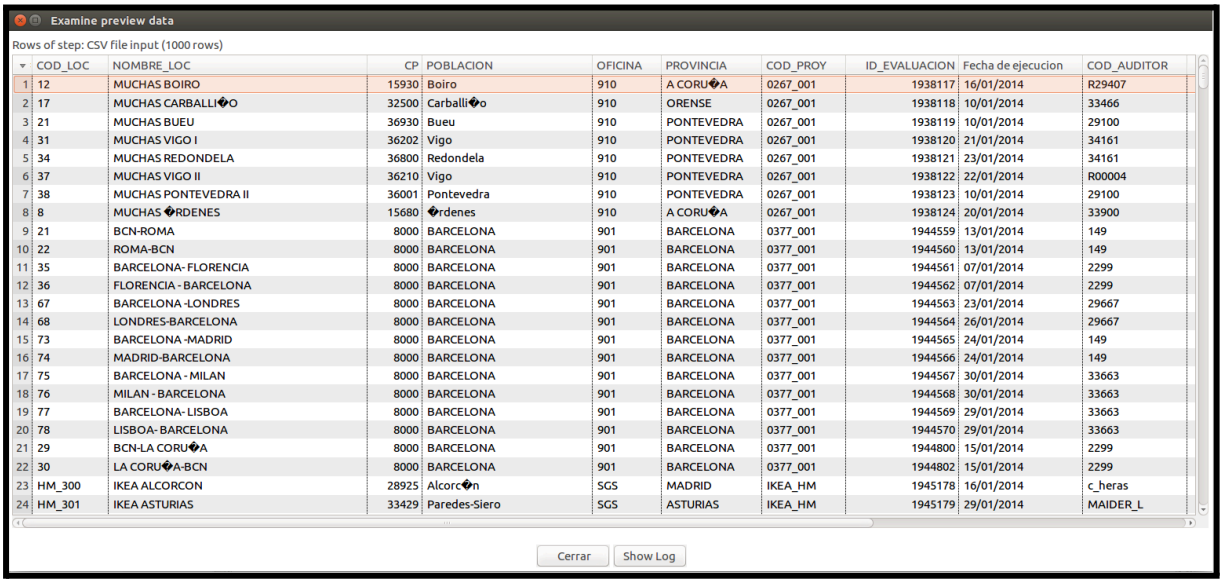

2. Salida Tabla:

a. Tabla destino: **ds_origen_ms.**

b. Vaciar Tabla (**check**).

c. Specify database fields (**check**).

d. Get fields.

e. Table fields igual que Stream fields.

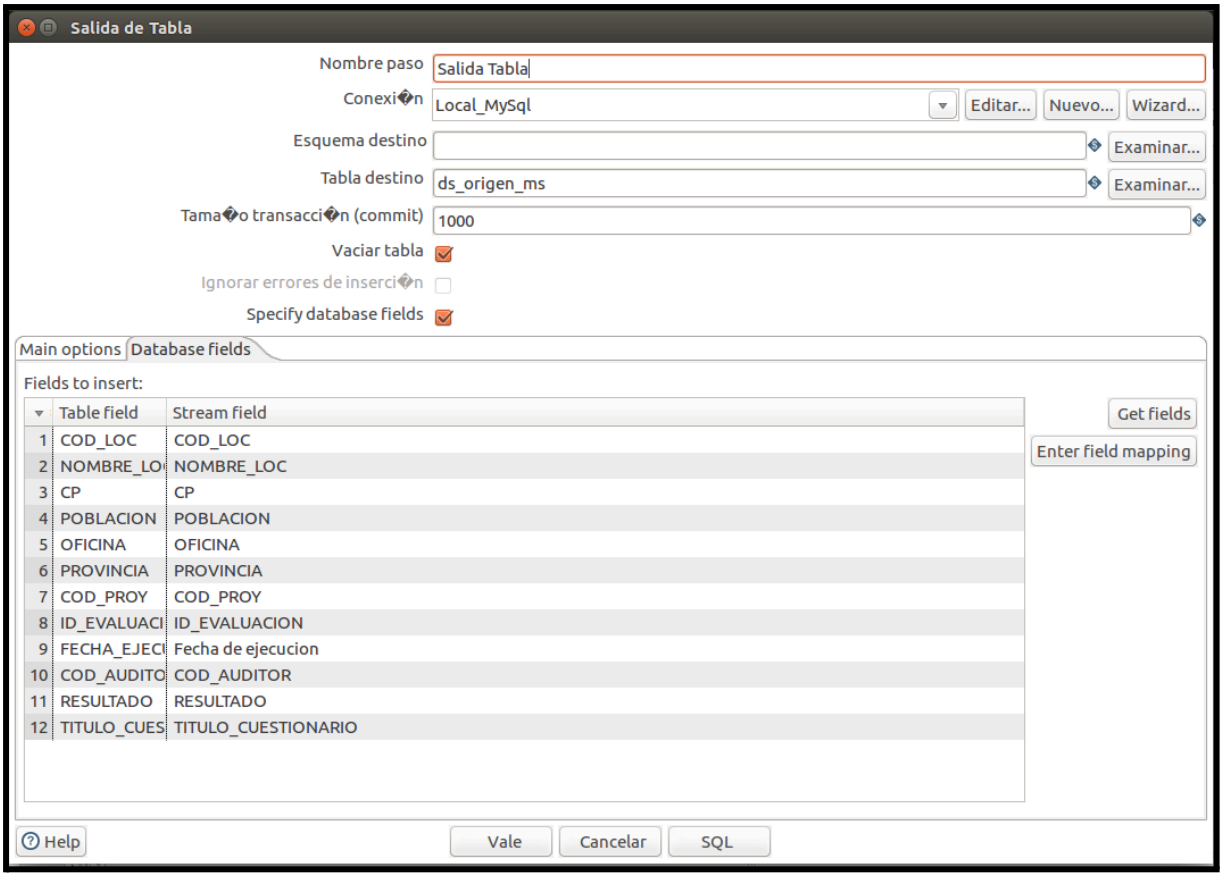

Limpieza_Datos.ktr

Esta transformación se compone de cinco pasos:

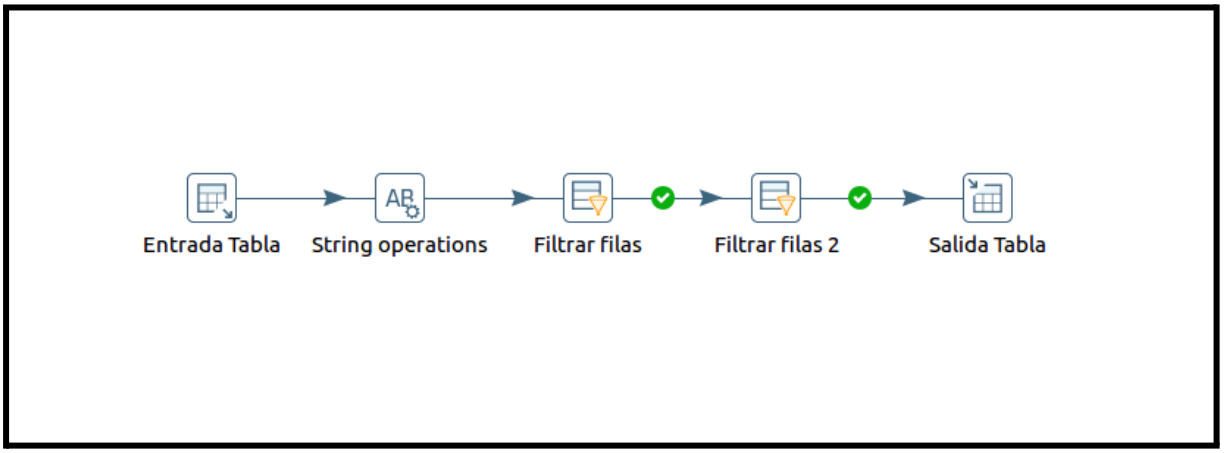

1. **Entrada Tabla:**

    a. SQL:

    SELECT *
    FROM ds_origen_ms;

b. Previsualizar.

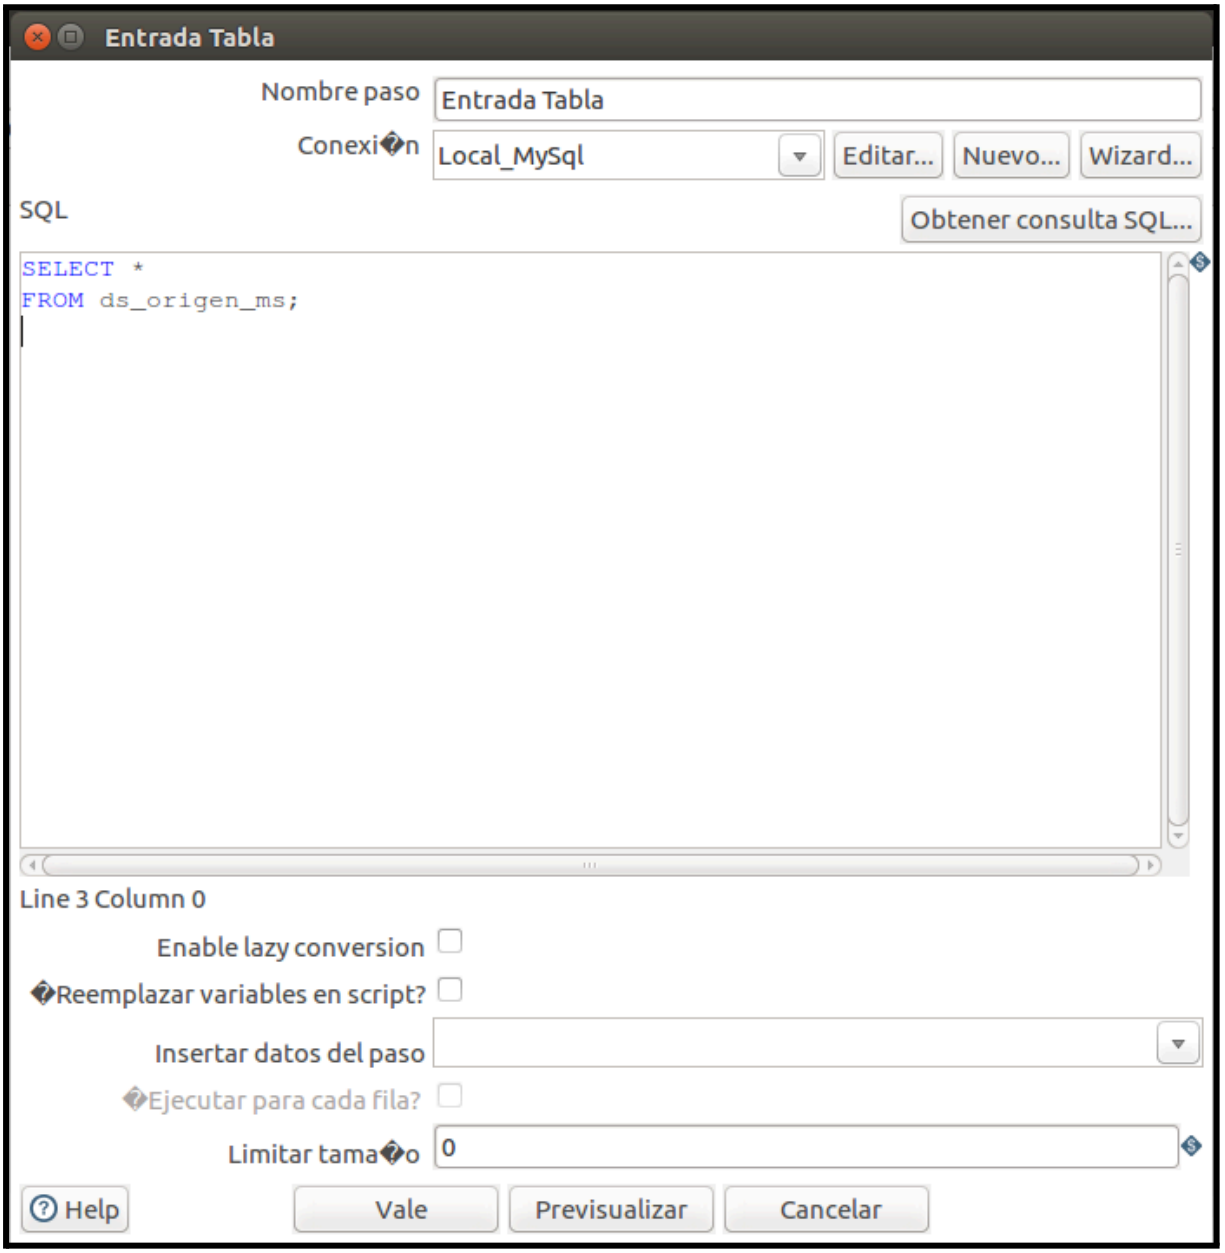

2. **String Operations**

   a. In stream field: **PROVINCIA**, **POBLACION**, **OFICINA**, **TITULO_CUESTIONARIO**.

   b. Trym type: **both**.

   c. Lower/upper: Solo Provincia **upper**.

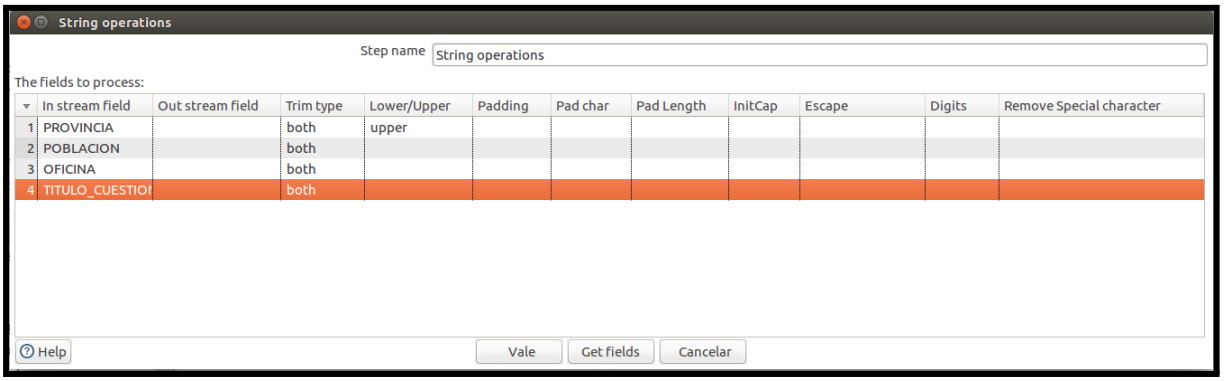

3. **Filtrar filas:**

   a. Condición:

   FECHA_EJECUCION IS NOT NULL

   AND

   COD_LOC IS NOT NULL

   AND

   RESULTADO IS NOT NULL

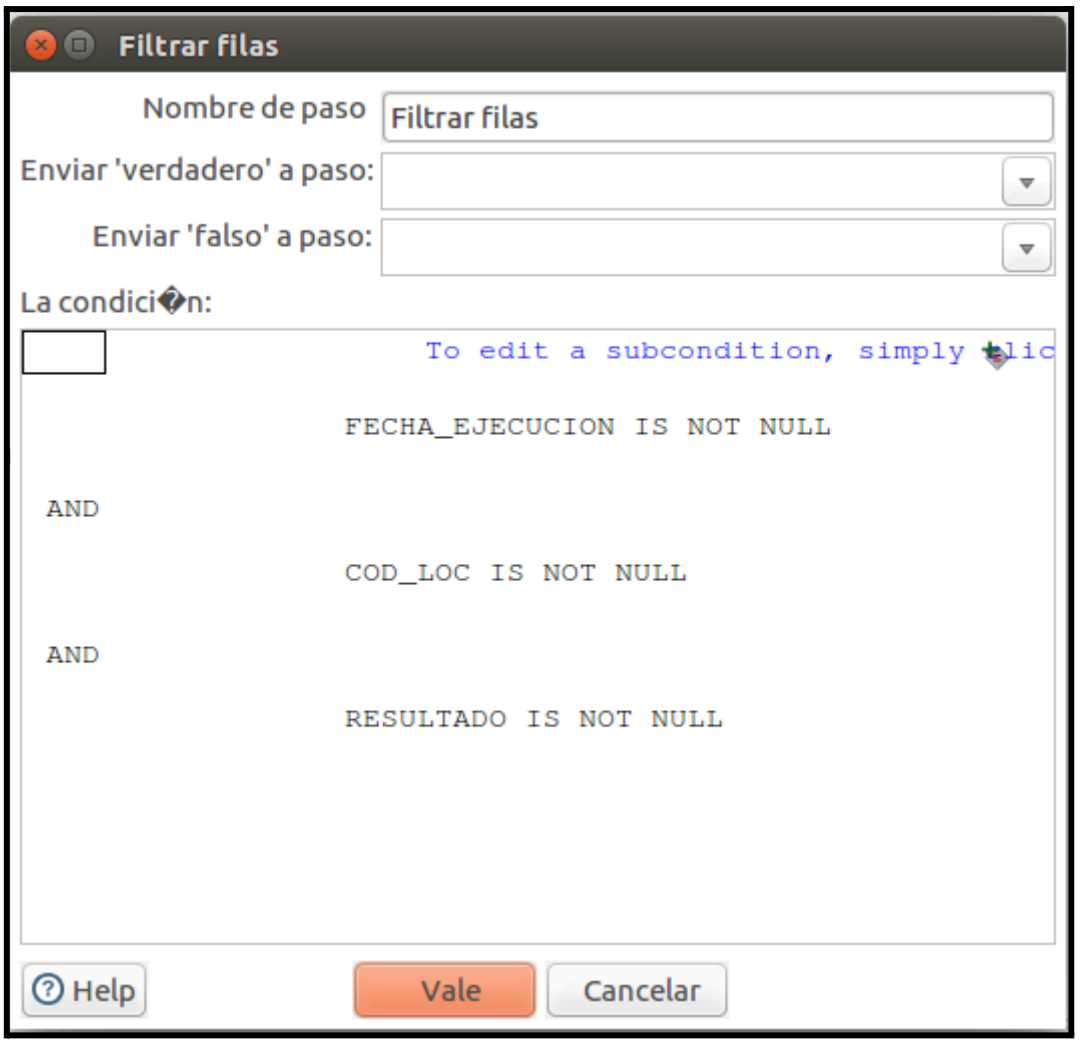

4. **Filtrar filas 2:**

    a. Condición:

    RESULTADO >= [0]

    AND

    RESULTADO <= [0]

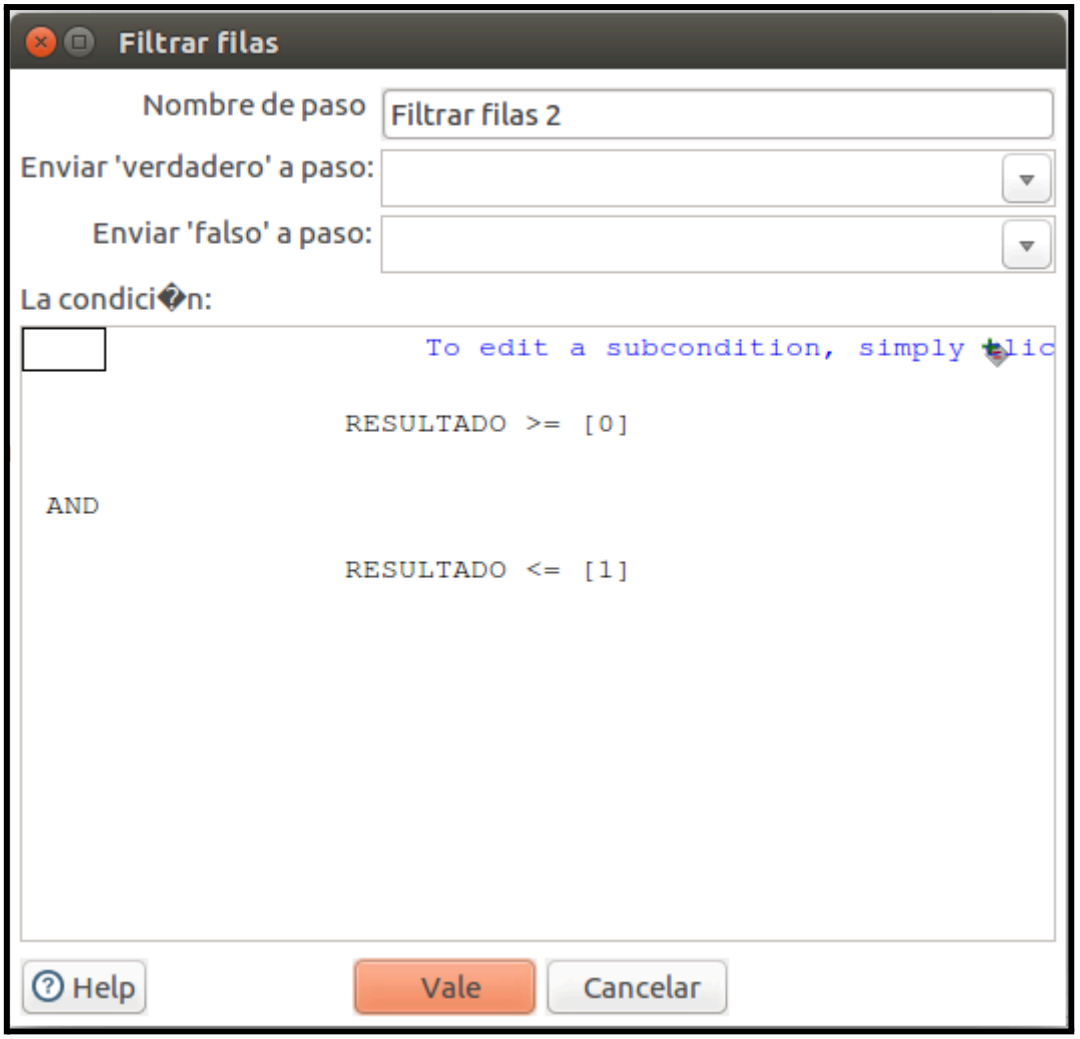

5. **Salida tabla:**

    a. Tabla destino: **dv_datoslimpios_ms**.

    b. Vaciar tabla: (**check**).

    c. Specify database fields: (**check**).

    d. Get Fields.

    e. Table fields igual que Stream fields.

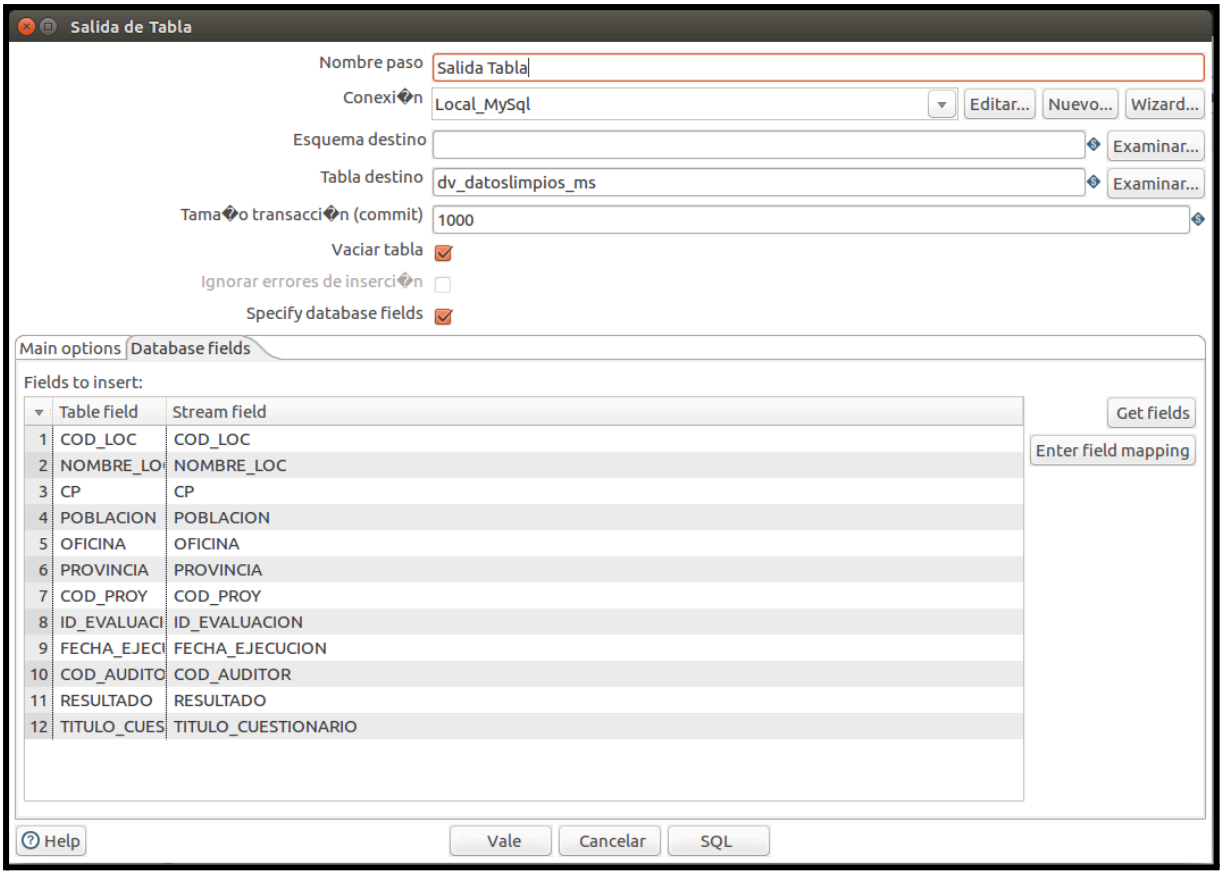

Dimension_Tiempo.ktr

Esta transformación se compone de tres pasos:

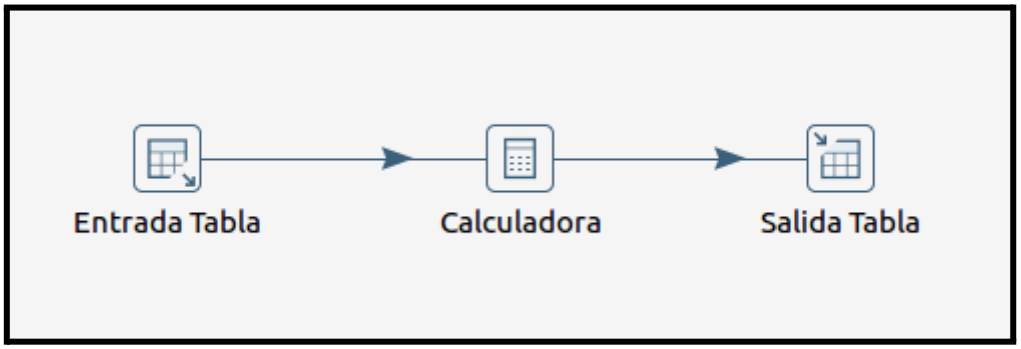

1. **Entrada tabla:**

   a. SQL:

```
SELECT DISTINCT
        FECHA EJECUCION AS FECHA
FROM dv_datoslimpios_ms;
```

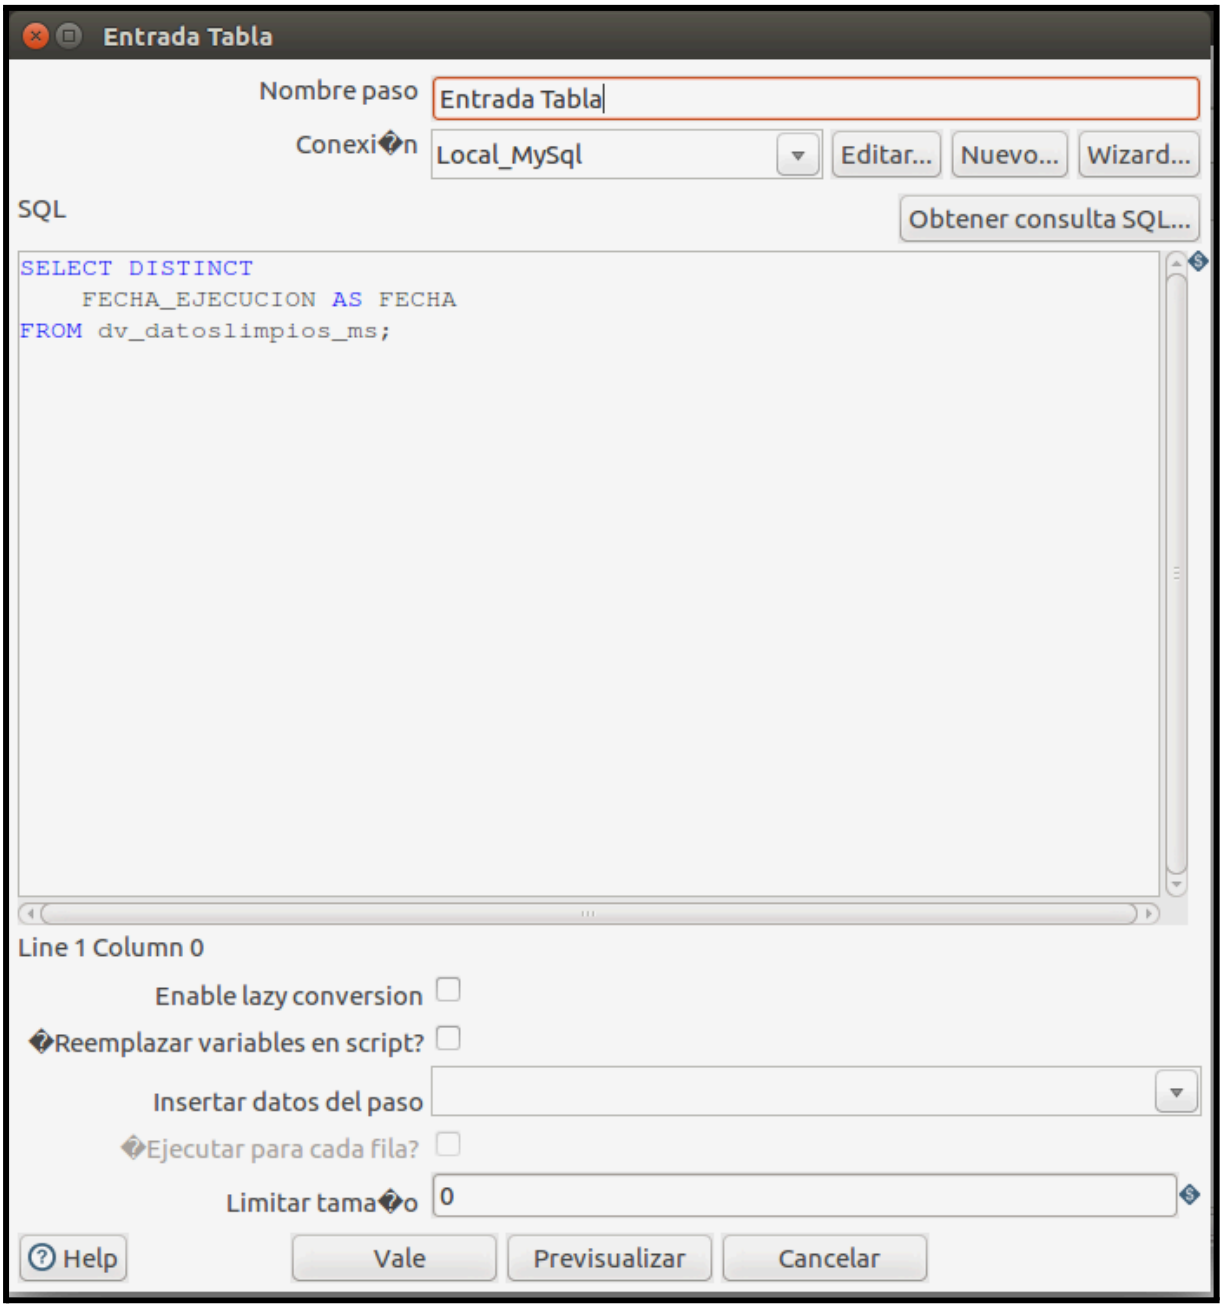

2. **Calculadora:**

   a.

Nuevo campo	**Cálculo**	**Campo A**	**Tipo de valor**
Anio	Año de fecha A	FECHA	Integer
Trimestre	Quarter of date A	FECHA	Integer
Mes	Mes de fecha A	FECHA	Integer

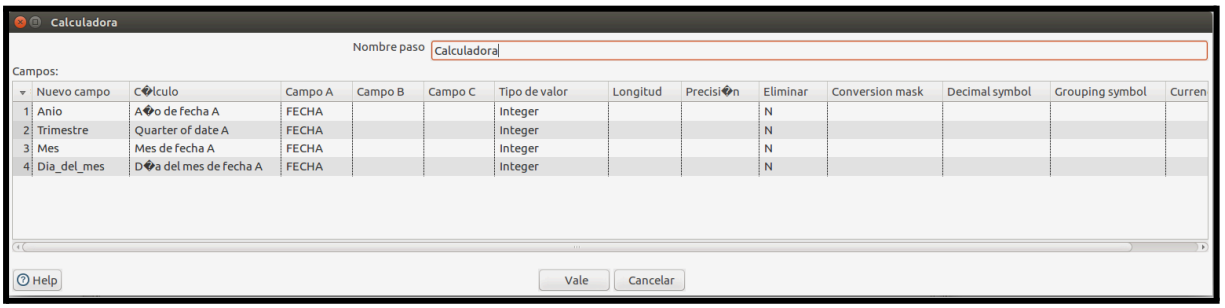

3. **Salida tabla:**

   a. Tabla destino: **dim_tiempo_full**.

   b. Vaciar tabla: (**check**).

   c. Specify database fields: (**check**).

   d. Get Fields.

   e. Table fields igual que Stream fields excepto FECHA >> Fecha Table field.

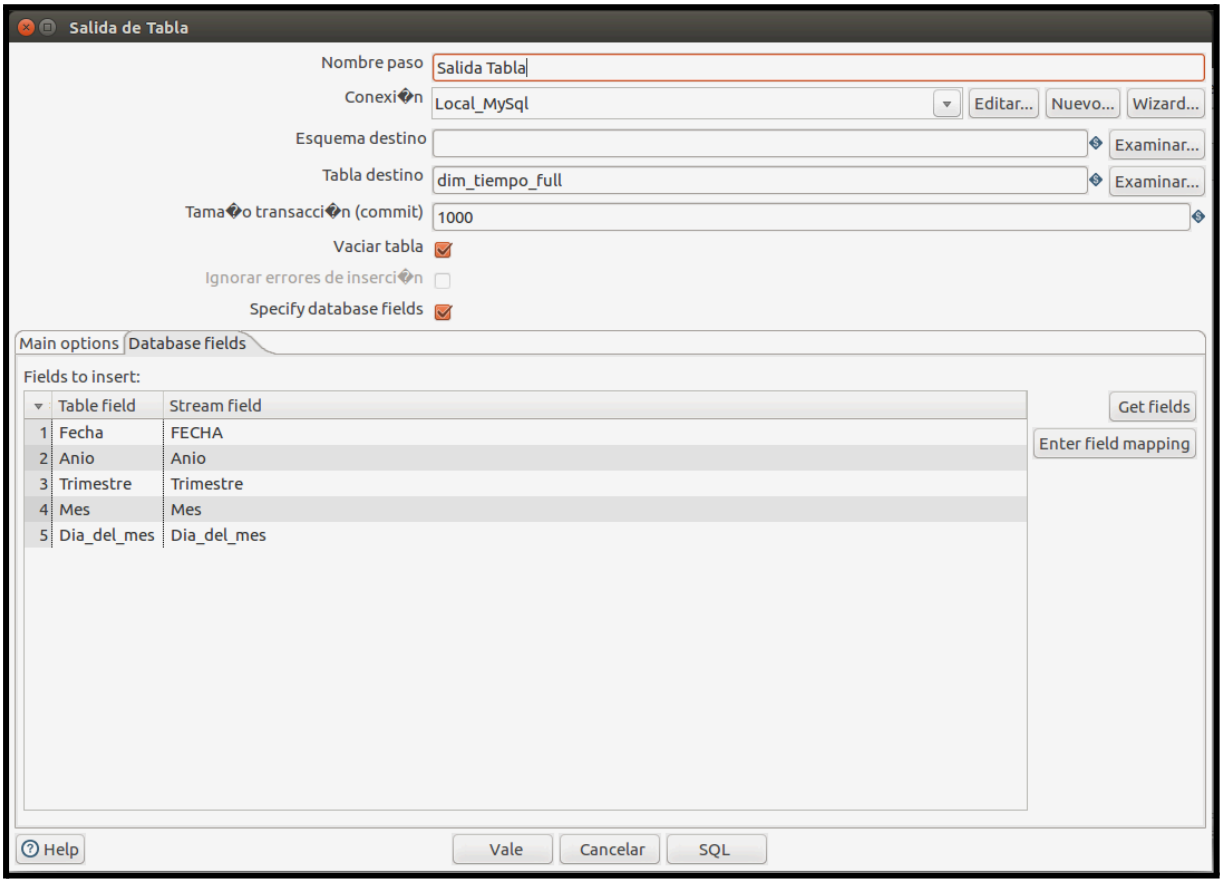

Dimension_Ubicacion.ktr

Esta transformación se compone de dos pasos:

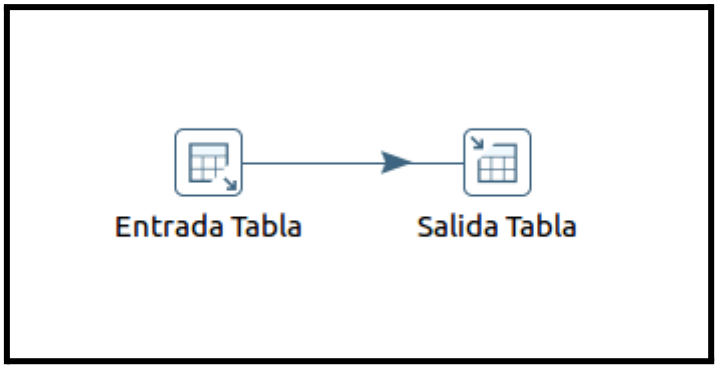

1. **Entrada Tabla**

   a. SQL:

```
SELECT DISTINCT
        PROVINCIA,
        POBLACION,
        CP,
        NOMBRE_LOC,
        COD_LOC
FROM dv_datoslimpios_ms;
```

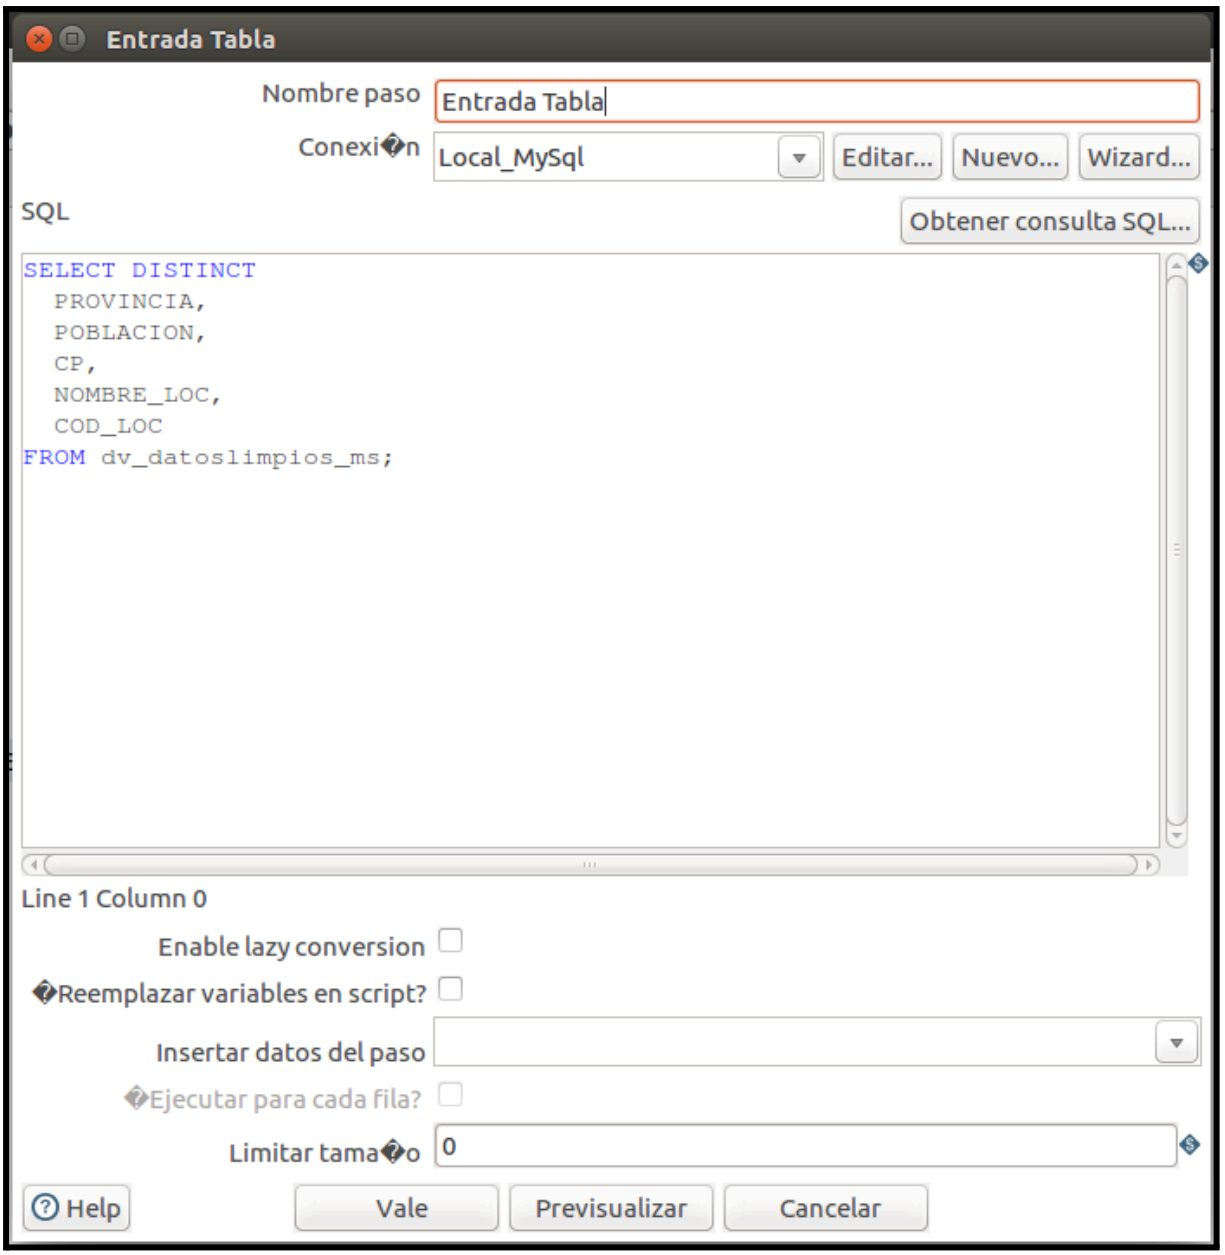

2. **Salida tabla:**

    a. Tabla destino: **dim_ubicacion**.

    b. Vaciar tabla: (**check**).

    c. Specify database fields: (**check**).

    d. Get Fields.

    e. Table fields en minúsculas.

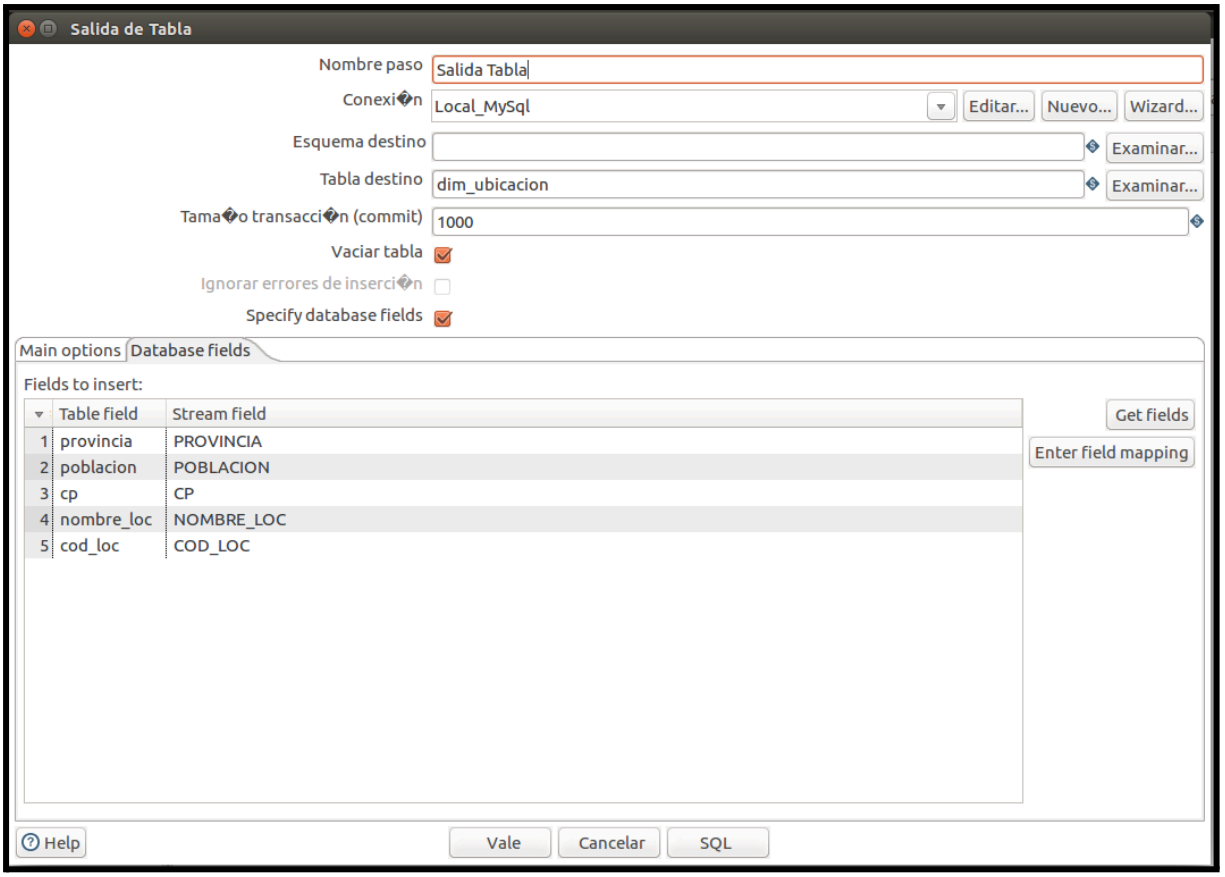

Dimension_Cuestionario.ktr

Esta transformación se compone de dos pasos:

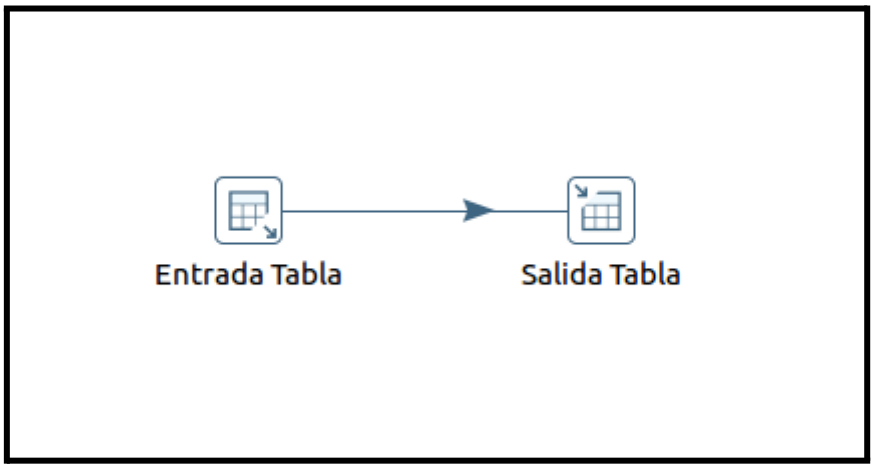

1. **Entrada Tabla:**

   a. SQL:

```
SELECT DISTINCT
        COD_PROY,
```

TITULO_CUESTIONARIO,
ID_EVALUACION
FROM dv_datoslimpios_ms;

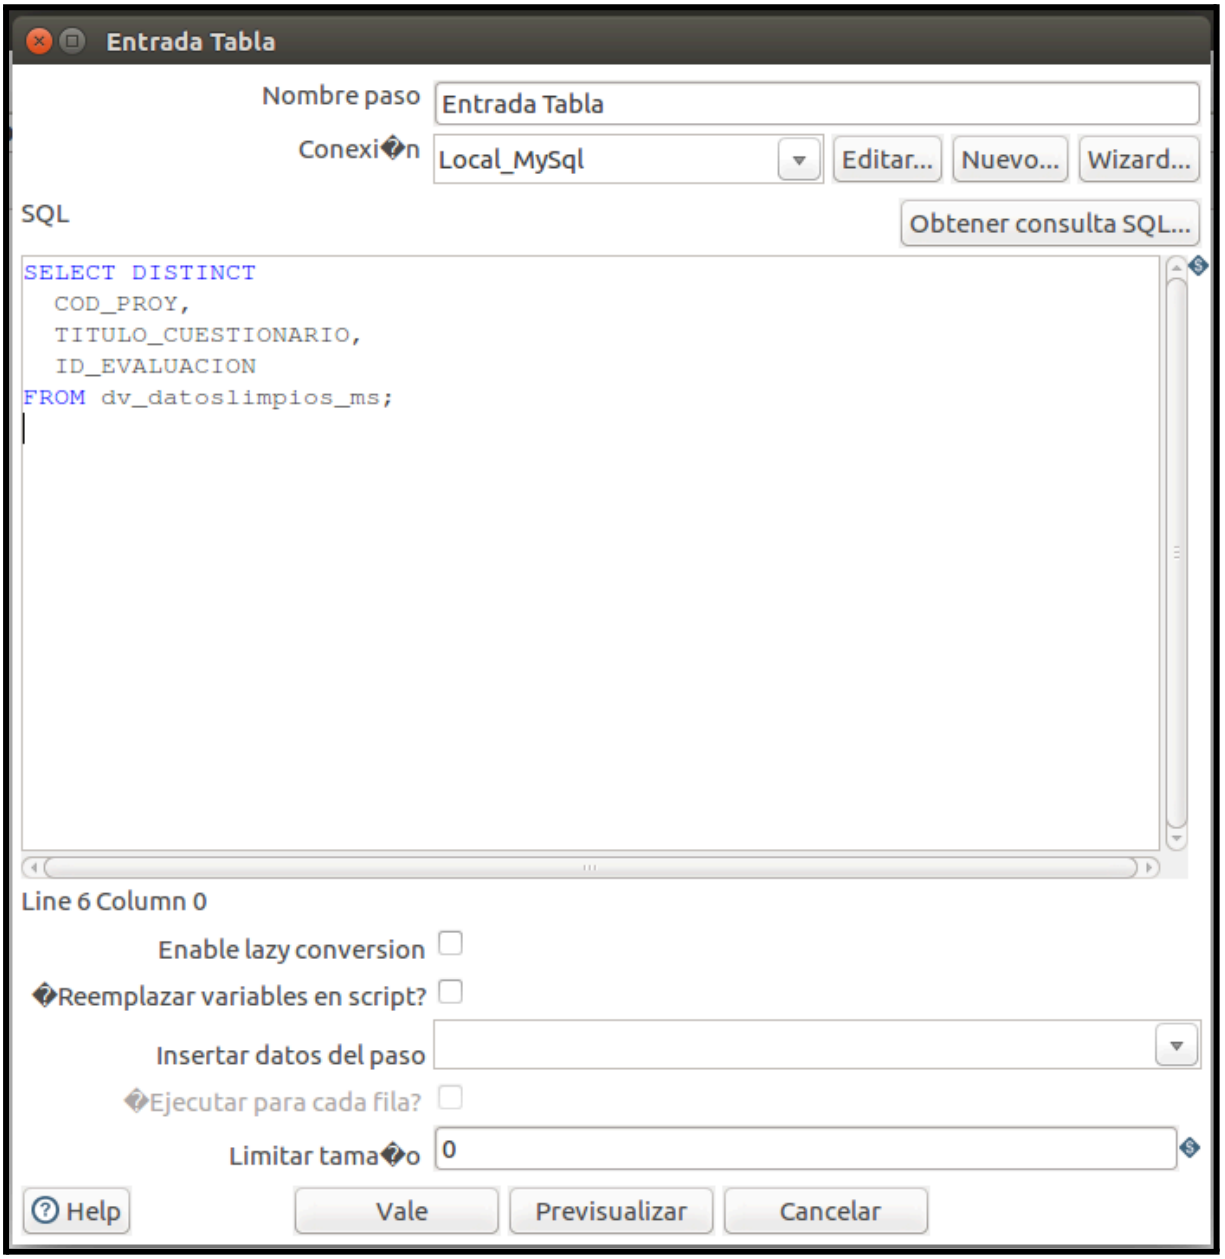

2. **Salida Tabla:**

   a. Tabla destino: **dim_cuestionario**.

   b. Vaciar tabla: (**check**).

   c. Specify database fields: (**check)**.

   d. Get Fields.

e. Table fields en minúsculas.

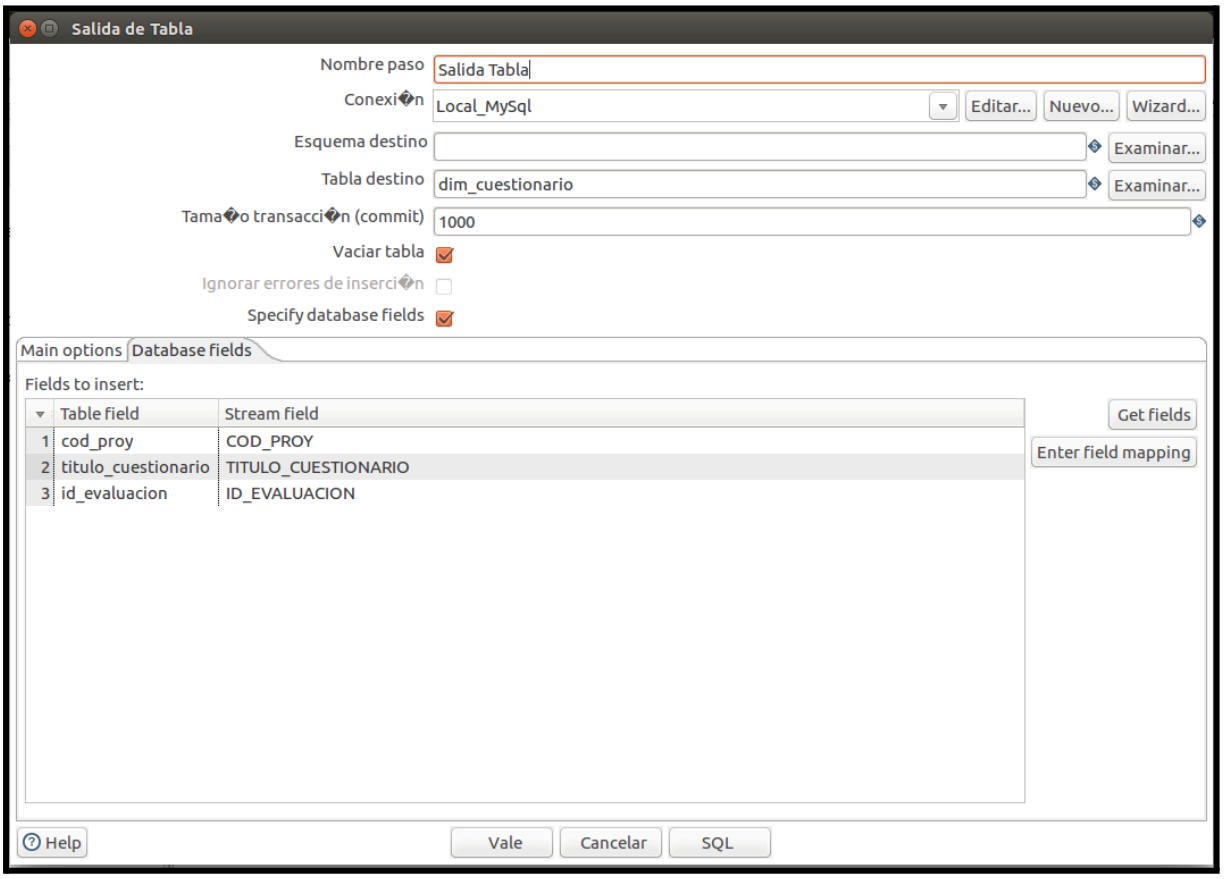

Dimension_Evaluador.ktr

Esta transformación se compone de dos pasos:

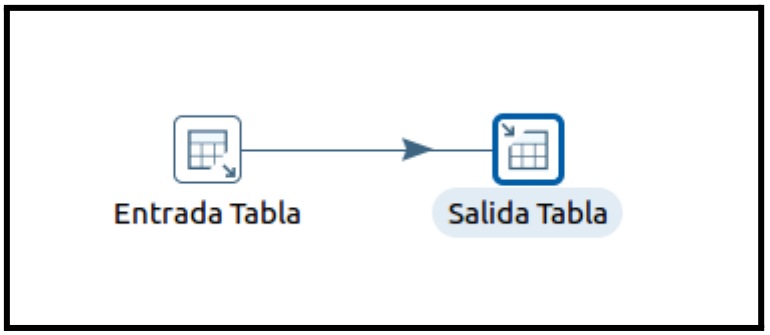

1. **Entrada Tabla:**

   a. SQL:

```
SELECT DISTINCT
        OFICINA,
        COD_AUDITOR
```

FROM dv_datoslimpios_ms;

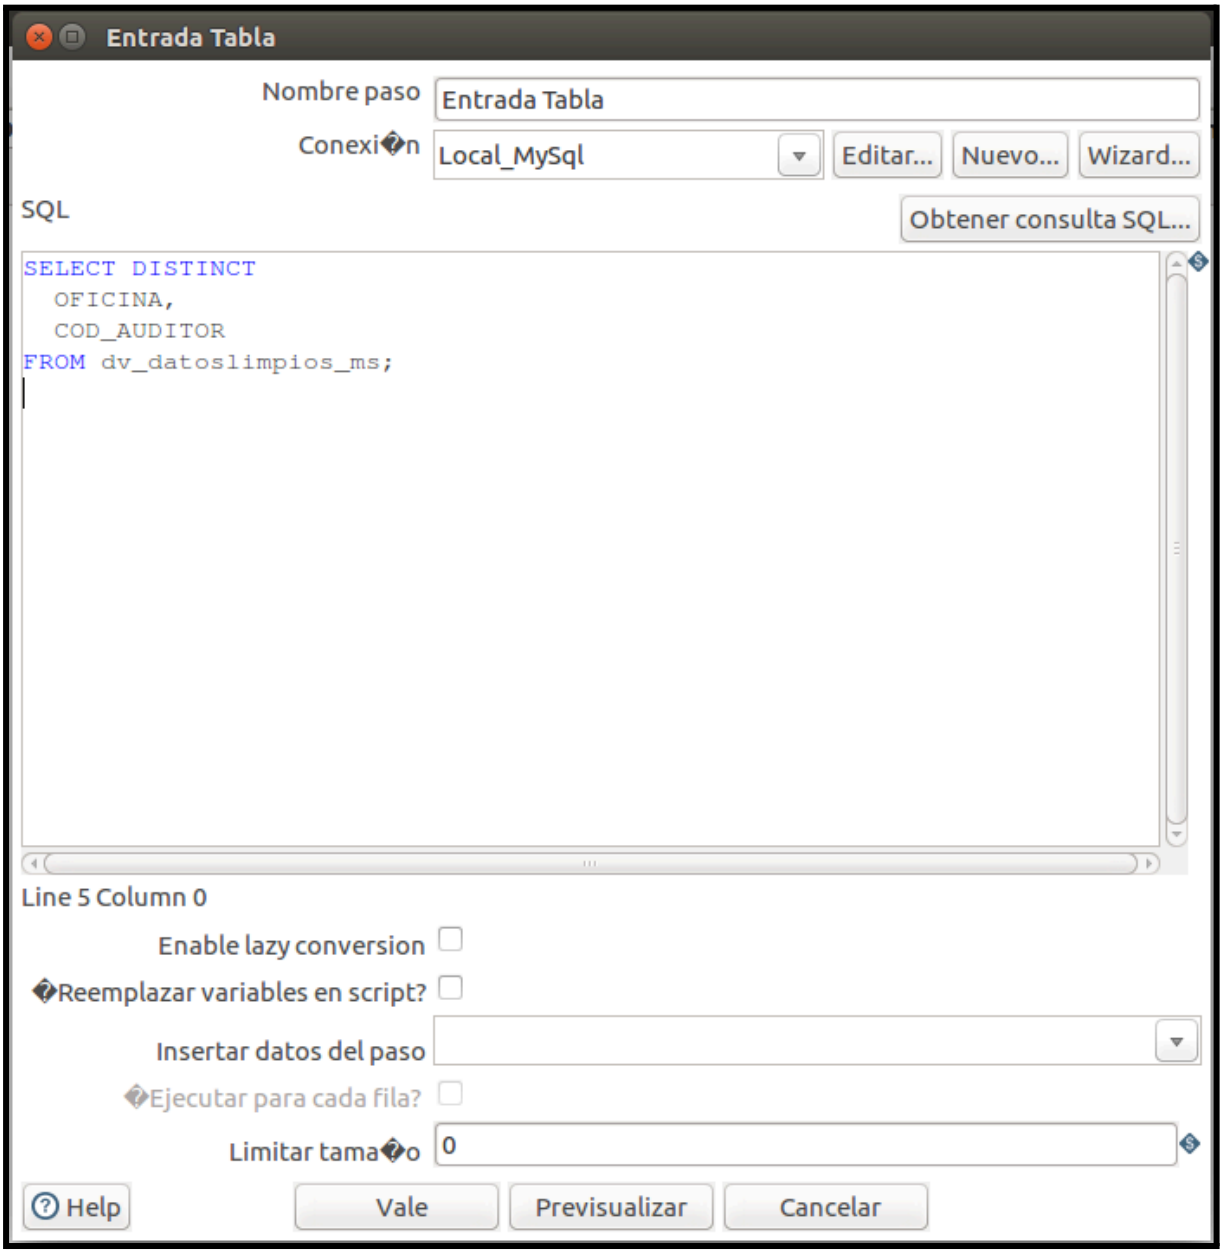

2. **Salida Tabla:**

   a. Tabla destino: **dim_evaluador**.

   b. Vaciar tabla: (**check**).

   c. Specify database fields: (**check**).

   d. Get Fields.

   e. Table fields en minúsculas.

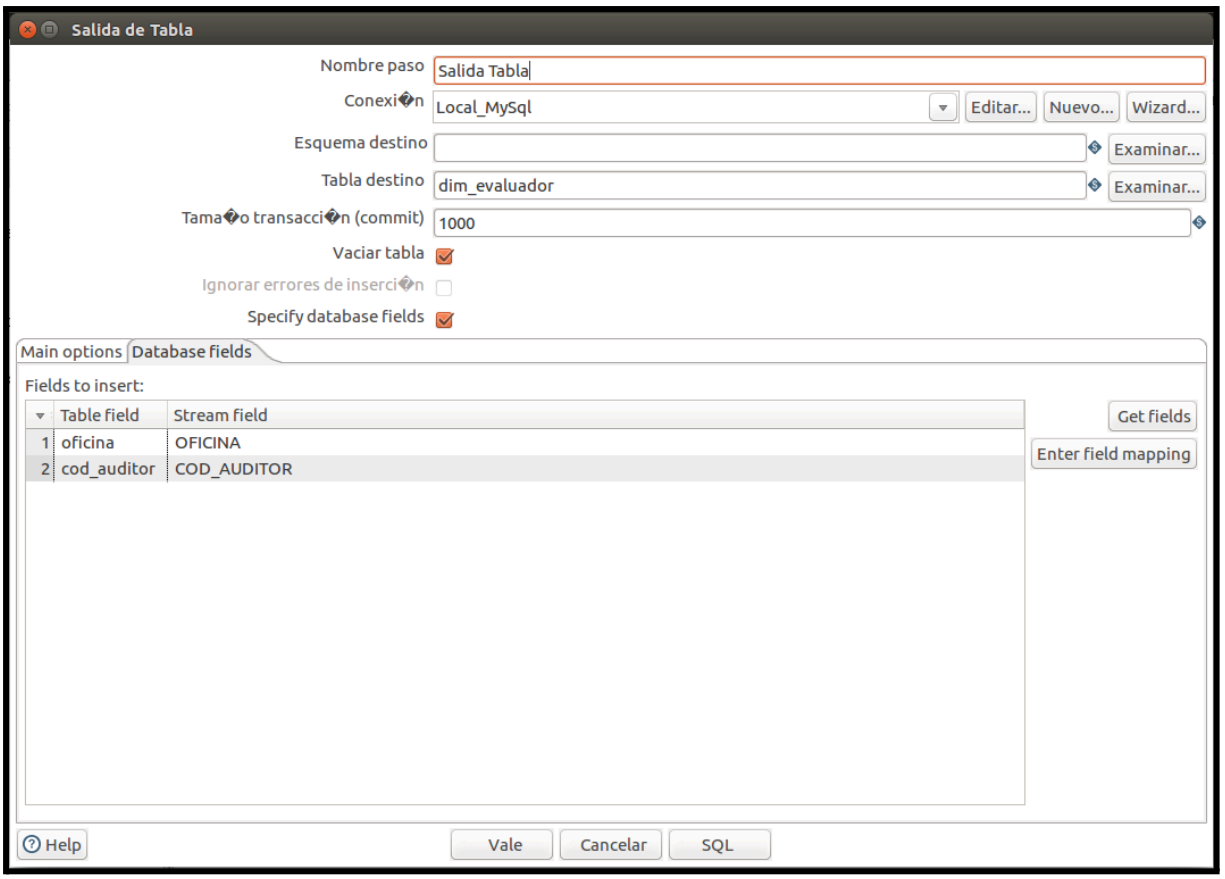

Hechos_Resultados.ktr

Esta transformación se compone de seis pasos:

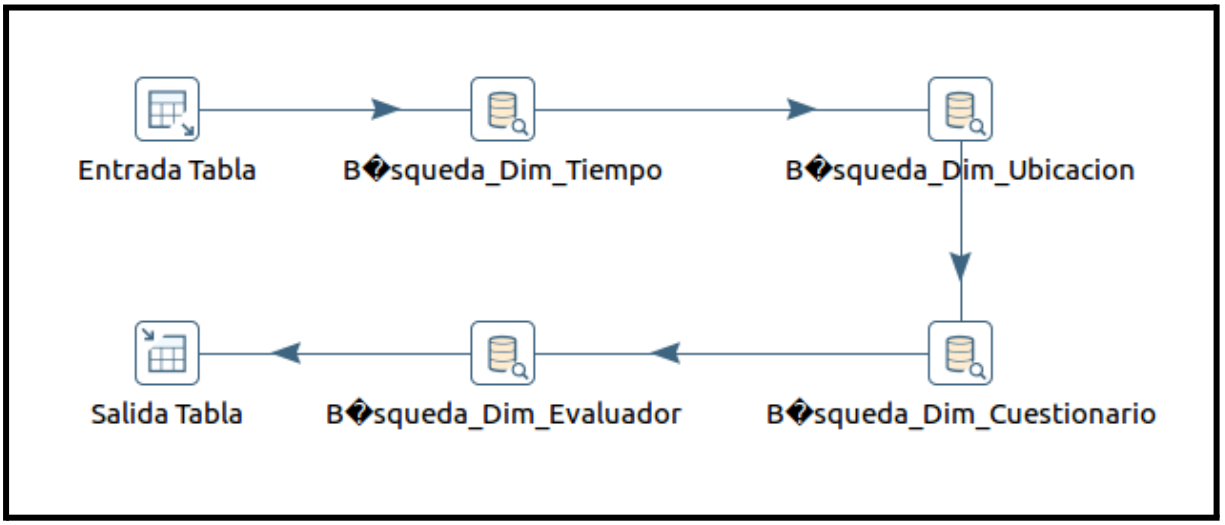

1. **Entrada Tabla:**

   a. SQL:

   SELECT DISTINCT

```
        FECHA_EJECUCION,
        COD_LOC,
        PROVINCIA,
        POBLACION,
        CP
        NOMBRE_LOC,
        COD_AUDITOR,
        COD_PROY,
        ID_EVALUACION,
        RESULTADO
FROM dv_datoslimpios_ms;
```

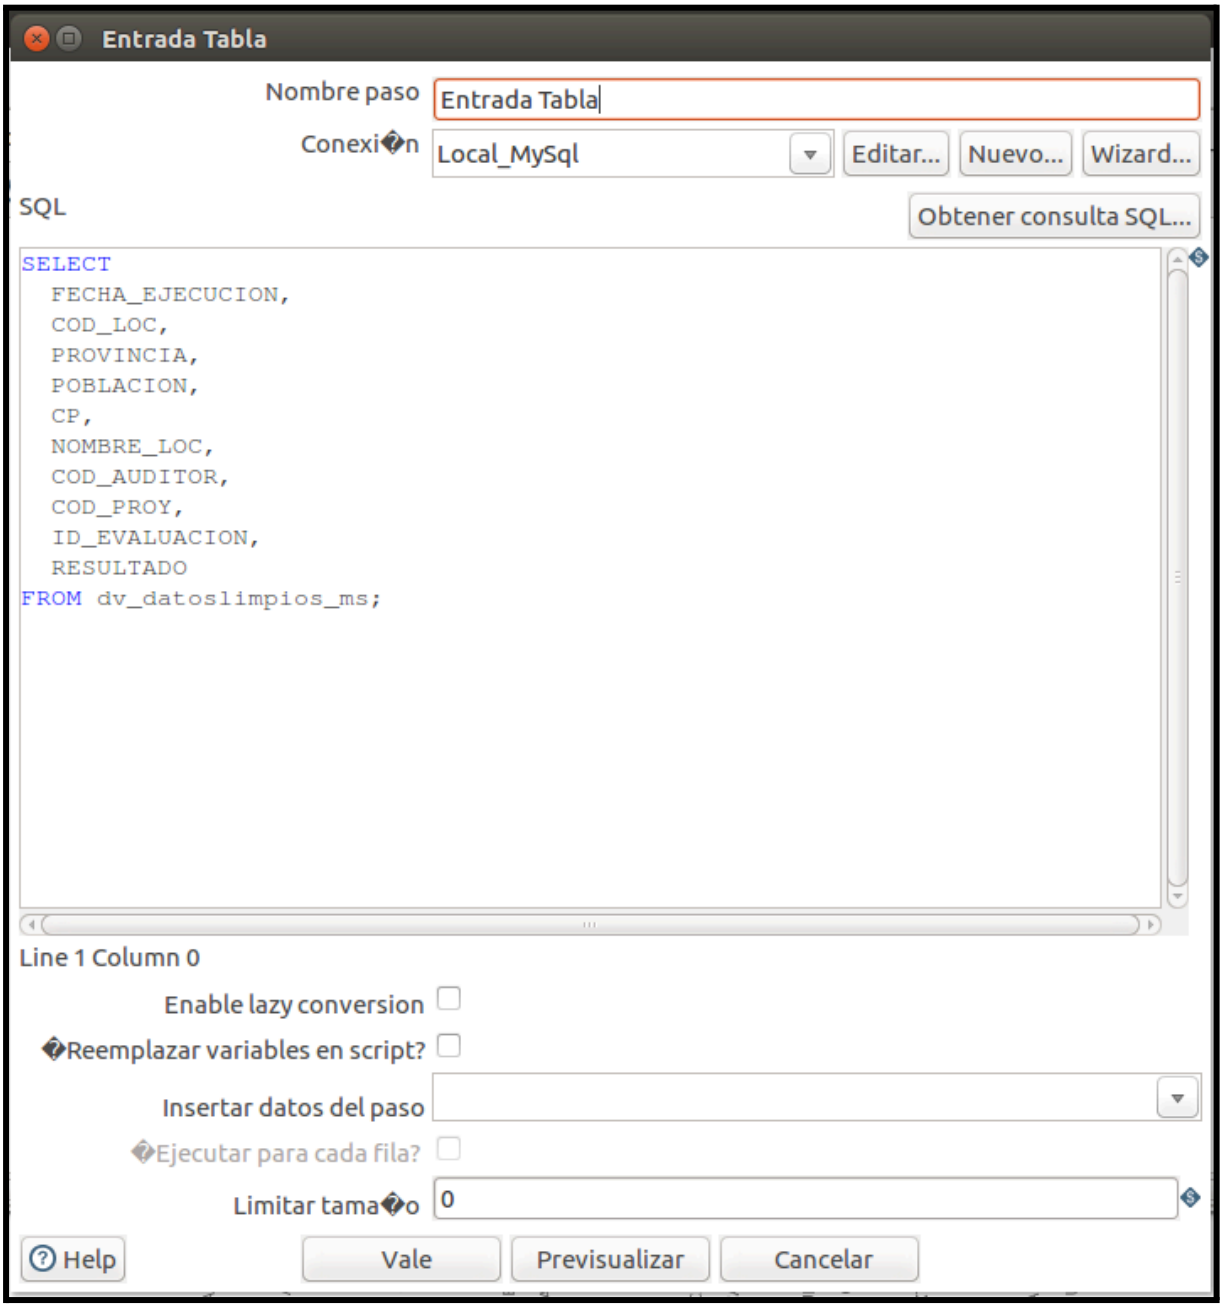

2. **Búsqueda_Dim_Tiempo:**

   a. Tabla de búsqueda: **dim_tiempo_full.**

   b.

Campo de tabla	Comparador	Campo1
fecha	=	FECHA_EJECUCION

   c.

Campo	Nuevo nombre
id_dim_tiempo	id_dim_tiempo

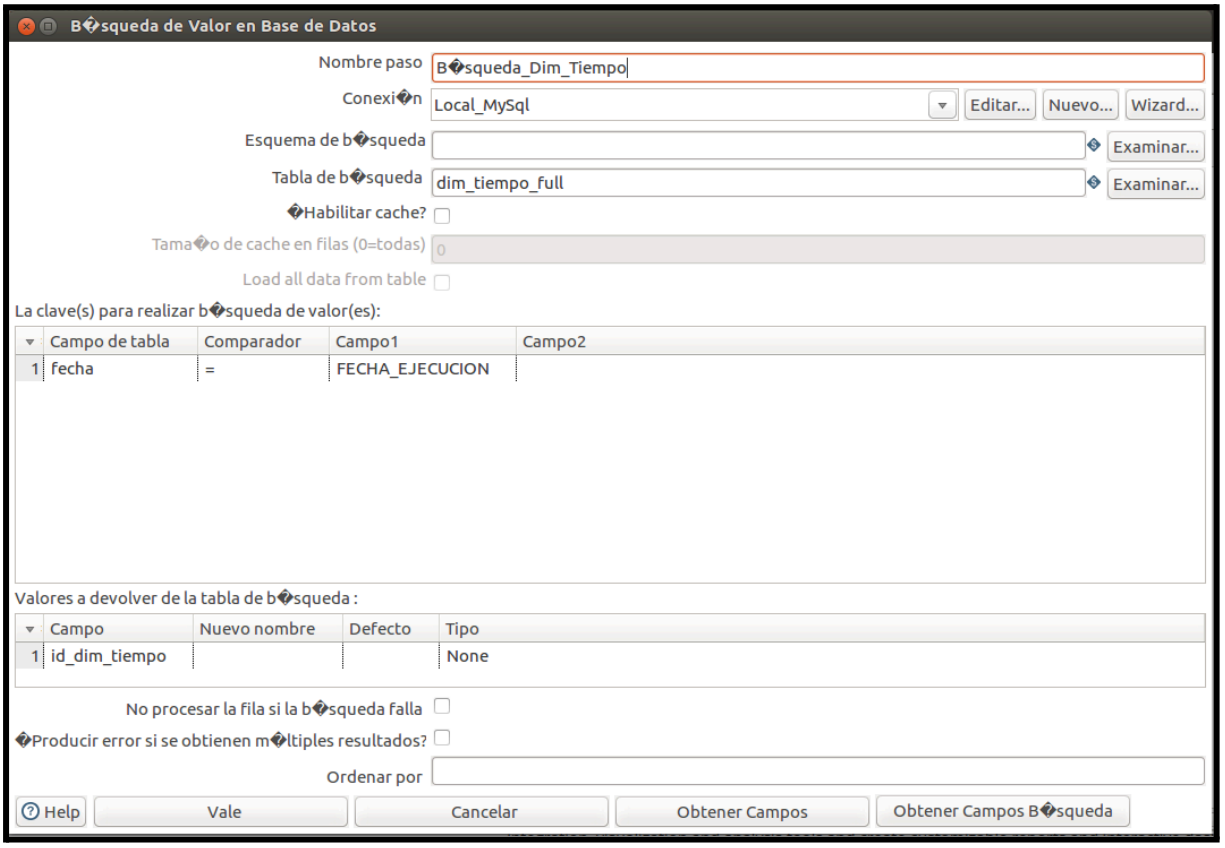

3. **Búsqueda_Dim_Ubicacion:**

   a. Tabla de búsqueda: **dim_ubicacion**.

   b.

Campo de tabla	Comparador	Campo1
cod_loc	=	COD_LOC

provincia	=	PROVINCIA
poblacion	=	POBLACION
cp	=	CP
nombre_loc	=	NOMBRE_LOC

c.

Campo	Nuevo nombre
id_dim_ubicacion	id_dim_ubicacion

d. ¿Producir error si se obtienen múltiples resultados?: (**check**).

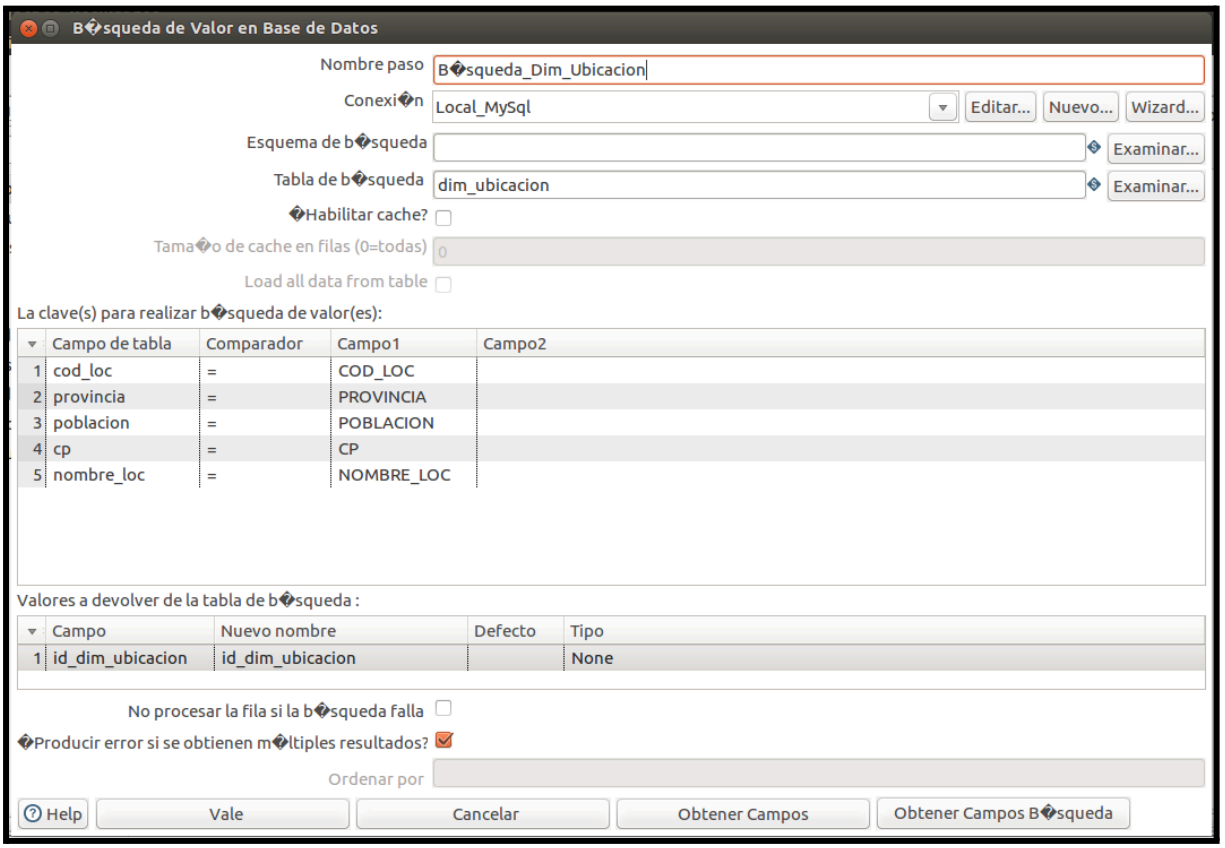

4. Búsqueda_Dim_Cuestionario:

a. Tabla de búsqueda: **dim_cuestionario**.

b.

Campo de tabla	Comparador	Campo1
id_evaluacion	=	ID_EVALUACION

c.

Campo	Nuevo nombre
id_dim_cuestionario	id_dim_cuestionario

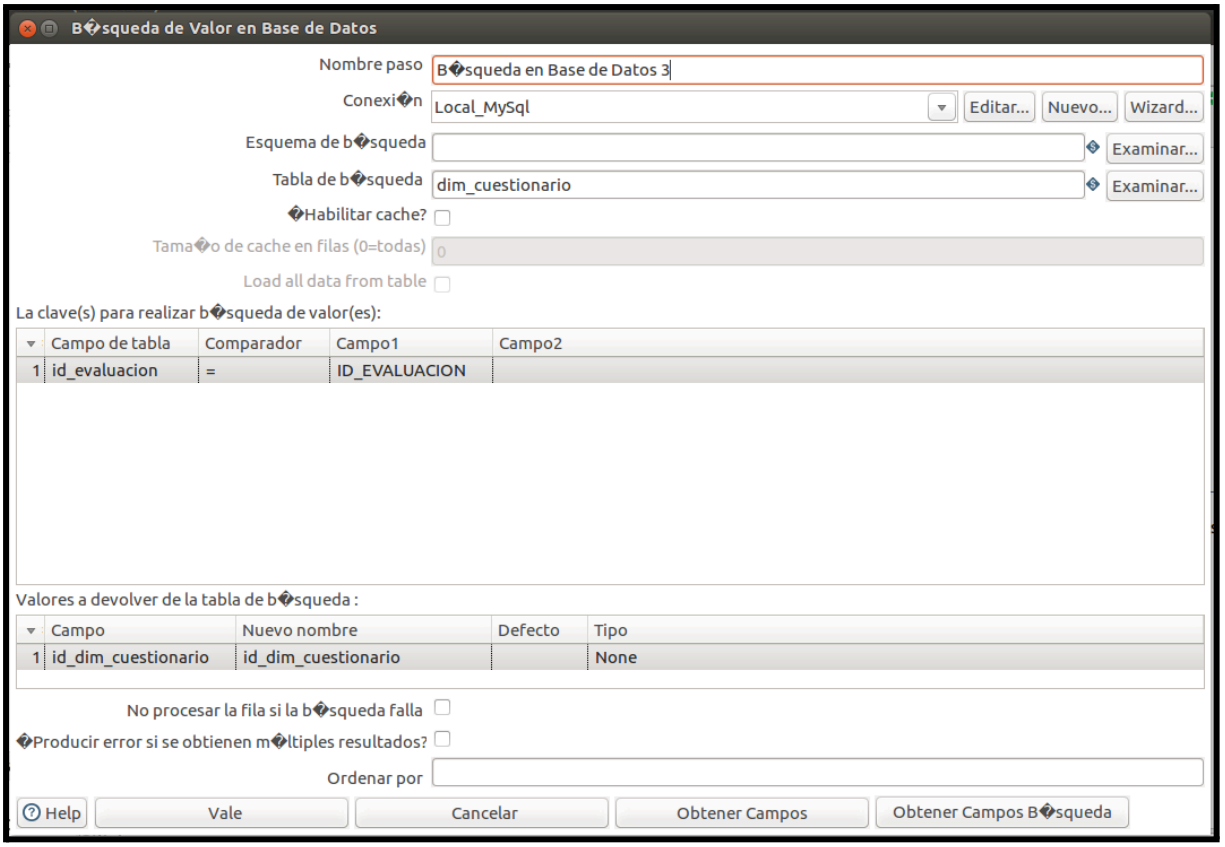

5. **Búsqueda_Dim_Evaluador:**

a. Tabla de búsqueda: **dim_evaluador**.

b.

Campo de tabla	Comparador	Campo1
cod_auditor	=	COD_AUDITOR

c.

Campo	Nuevo nombre
id_dim_auditor	id_dim_auditor

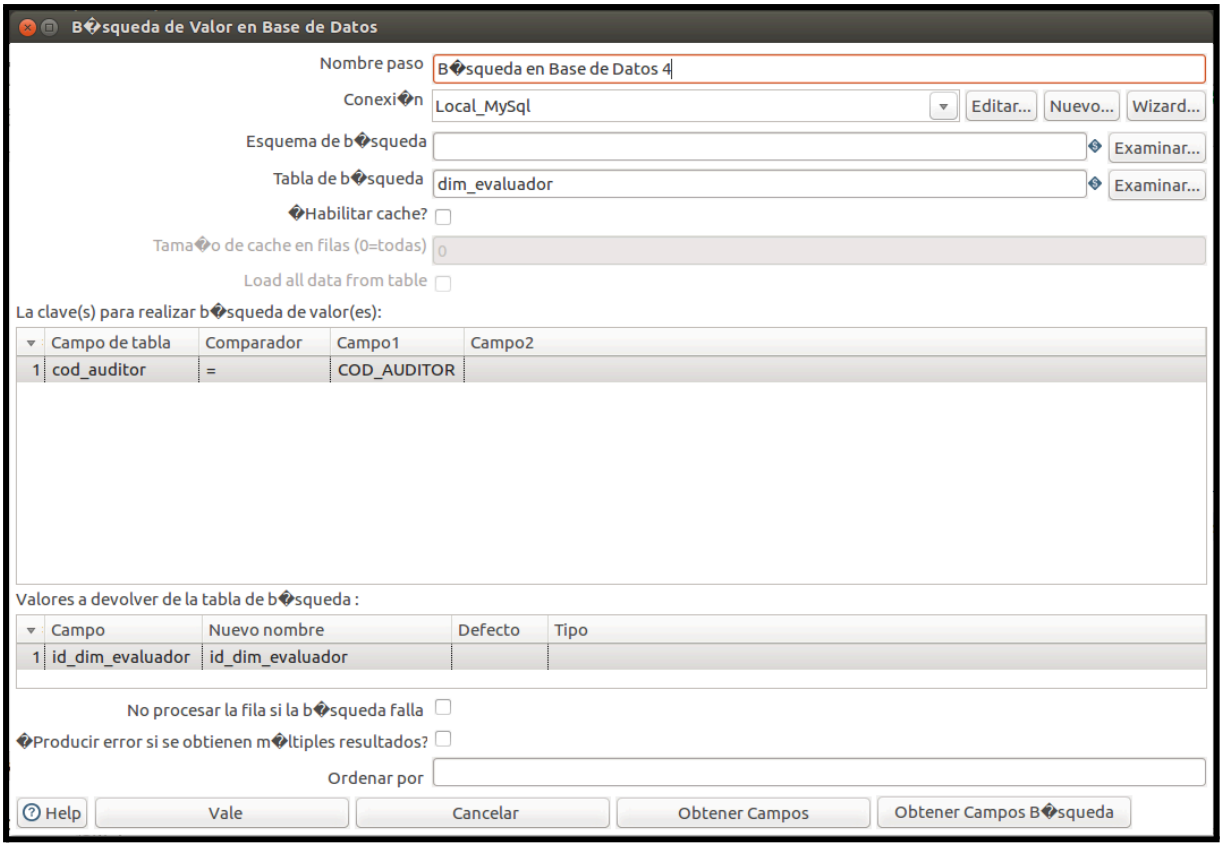

3. **Salida Tabla:**

    a. Tabla destino: **h_resultados**.

    b. Vaciar tabla: (**check**).

    c. Specify database fields: (**check**).

    d. Get Fields.

    e. Table fields igual que Stream fields.

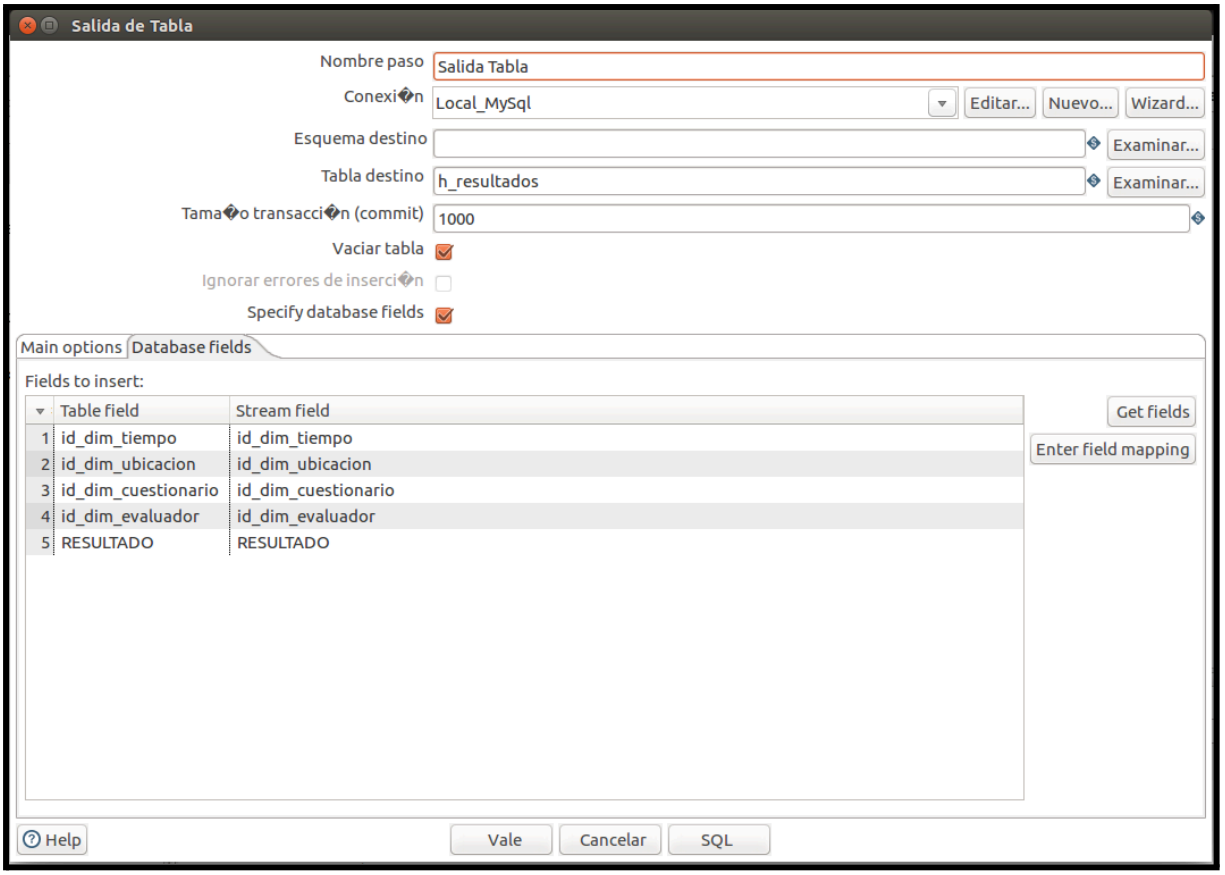

11. Implementación de modelo multidimensional diseñado mediante los puntos anteriores. Se debe realizar con la herramienta wizard facilitada y mostrada en vídeos anteriores.

1. **Accedemos a Pentaho Server y creamos un nuevo Data Source.**

    a. Data Source Name: **Caso_Practico_BI**.

    b. Source Type: **Database Table(s)**.

    c. Connection: **MySql Local**.

    d. Reporting and Analysis: (**check**).

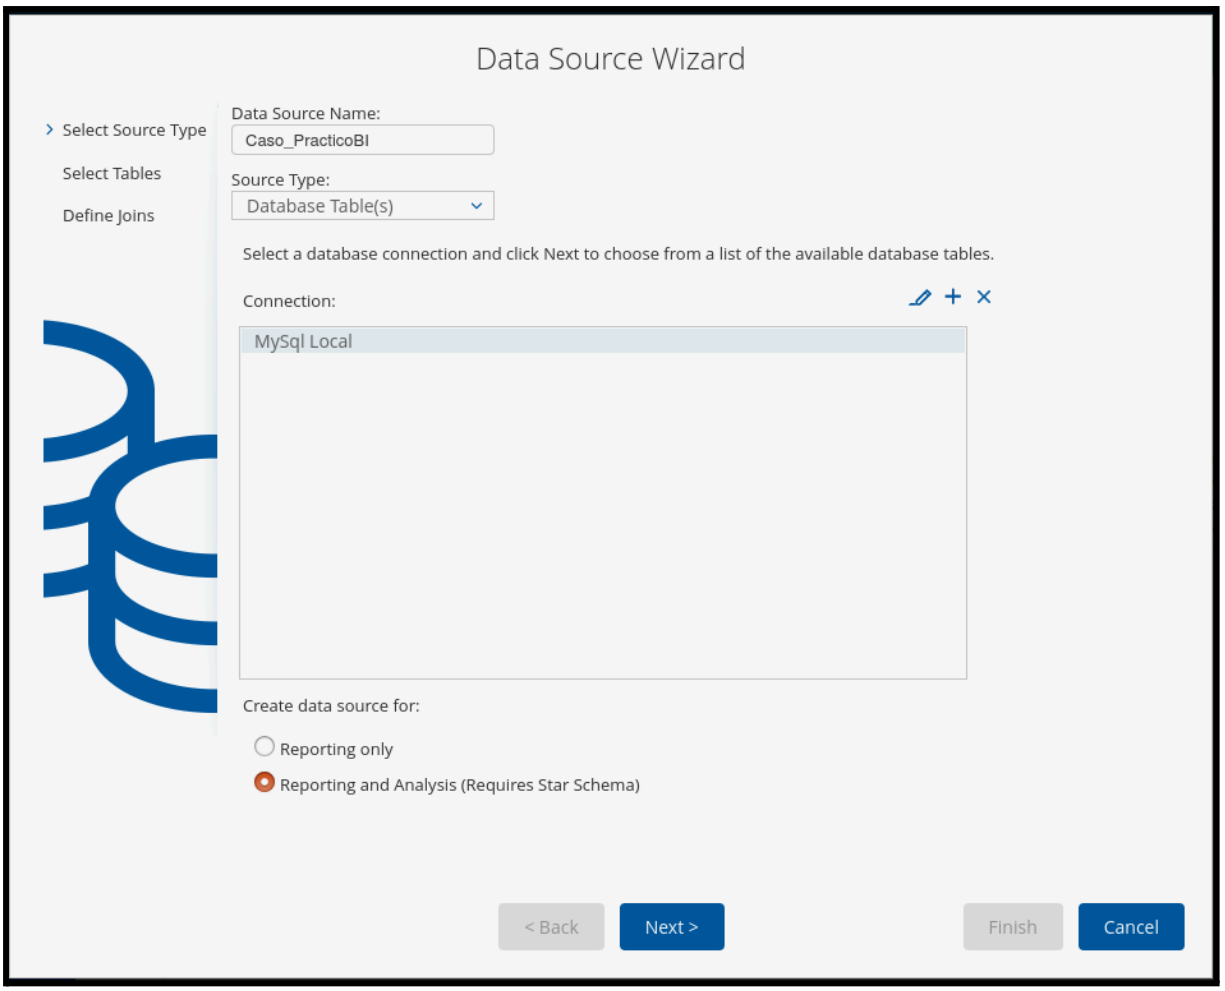

2. **Seleccionamos las tablas necesarias:**

   a. Schema: **master_imf**.

   b.

Selected Tables
`master_imf` . `h.resultados`
`master_imf` . `dim_tiempo_full`
`master_imf` . `dim_ubicacion`
`master_imf` . `dim_evaluador`
`master_imf` . `dim_cuestionario`

   c. Fact Table: **`master_imf` . `h.resultados`**

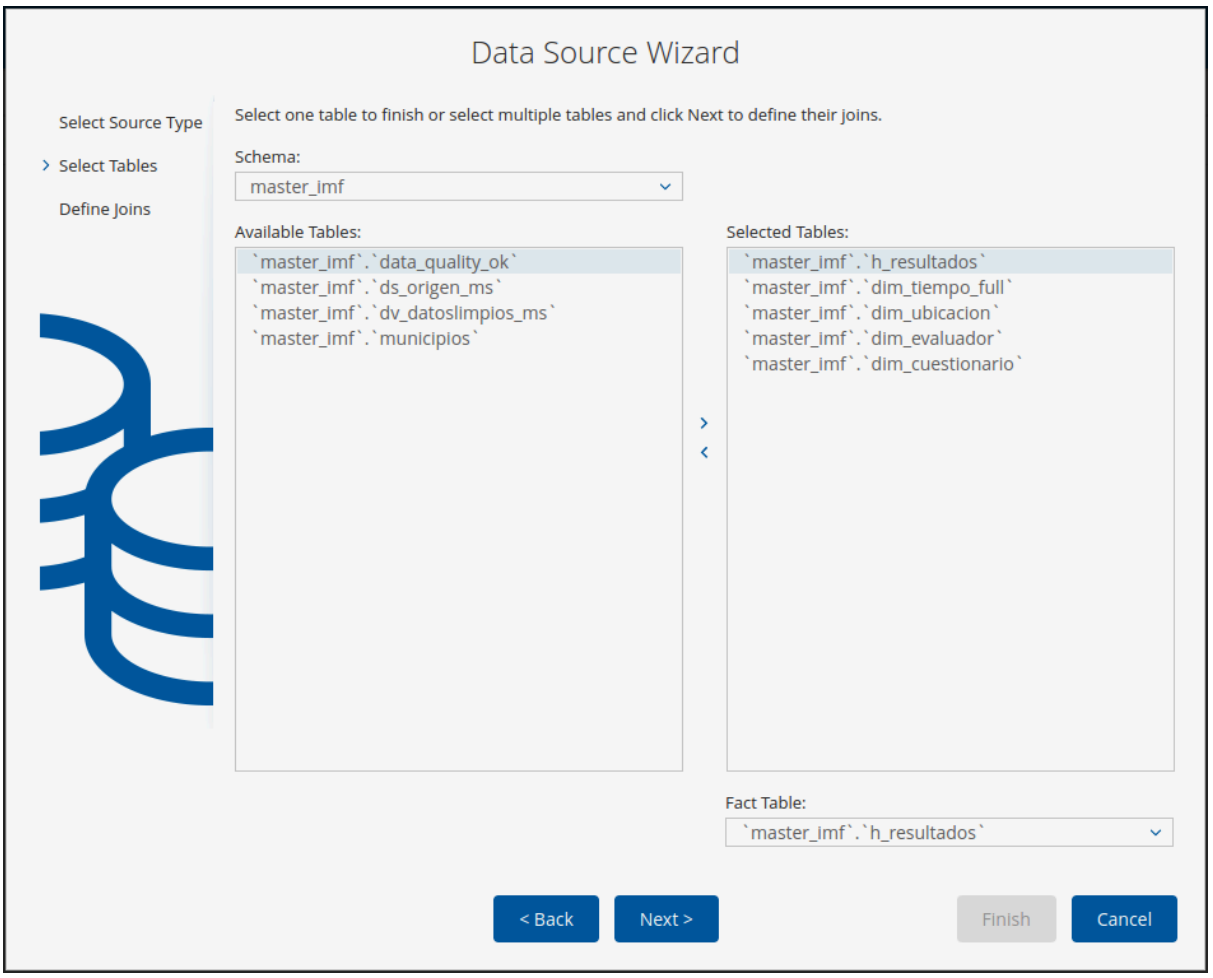

3. **Creamos los joins para establecer las relaciones entre las tablas:**

   a. **Join Tiempo:**

Left Table	**Right Table**
`master_imf` . `h.resultados`	`master_imf` . `dim_tiempo`

Key Field	**Key Field**
id_dim_tiempo	id_dim_tiempo

   b. **Join Ubicación:**

Left Table	**Right Table**
`master_imf` . `h.resultados`	`master_imf` . `dim_ubicacion`

Key Field	Key Field
id_dim_ubicacion	id_dim_ubicacion

c. **Join Cuestionario:**

Left Table	Right Table
`master_imf` . `h.resultados`	`master_imf` . `dim_cuestionario`

Key Field	Key Field
id_dim_cuestionario	id_dim_cuestionario

d. **Join Tiempo:**

Left Table	Right Table
`master_imf` . `h.resultados`	`master_imf` . `dim_evaluador`

Key Field	Key Field
id_dim_evaluador	id_dim_evaluador

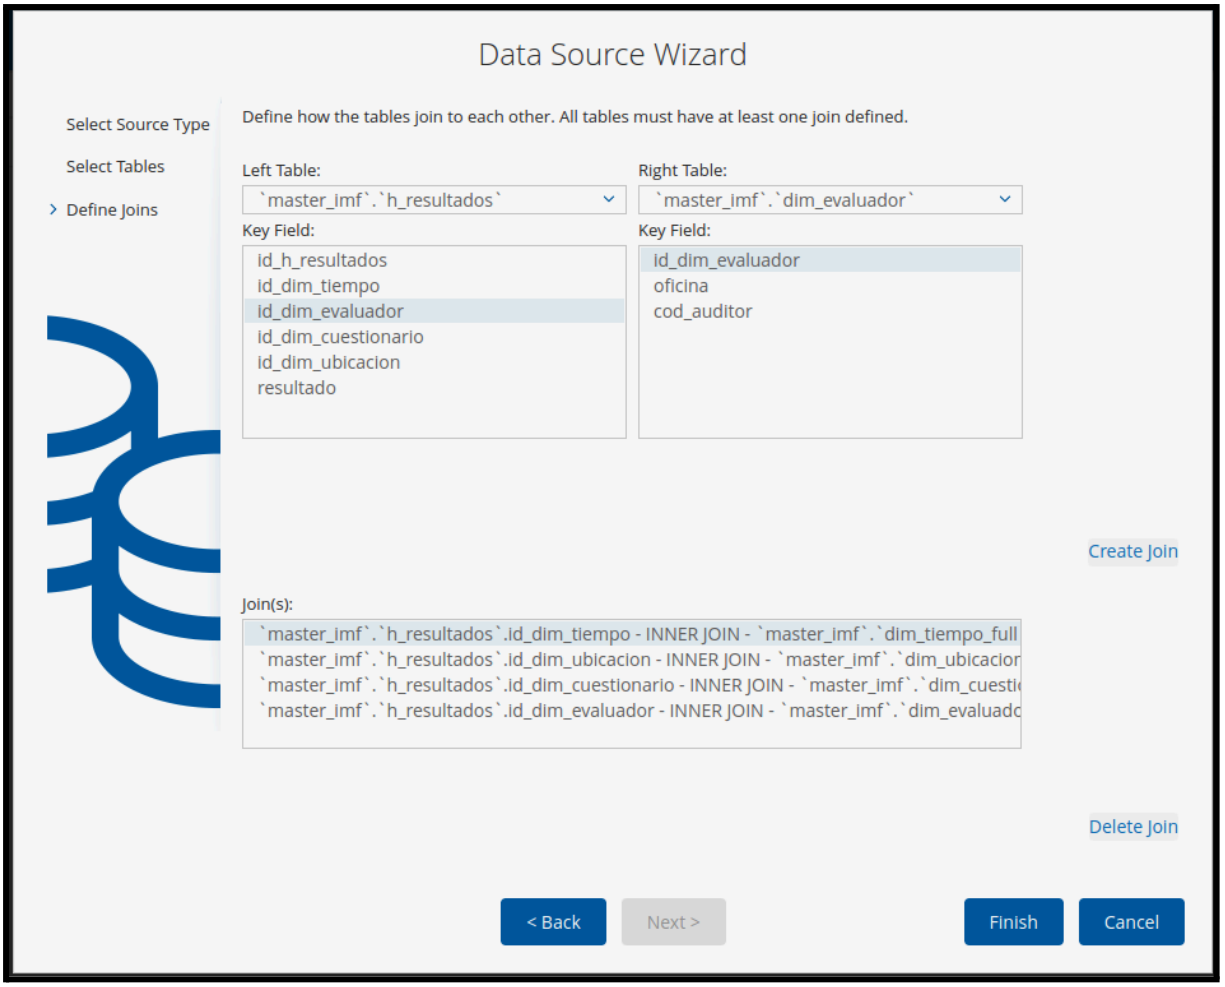
Data Source Wizard
Select Source Type
Select Tables
Define Joins
Define how the tables join to each other. All tables must have at least one join defined.
Left Table:
`master_imf`.`h_resultados`
Right Table:
`master_imf`.`dim_evaluador`
Key Field:
id_h_resultados
id_dim_tiempo
id_dim_evaluador
id_dim_cuestionario
id_dim_ubicacion
resultado
Key Field:
id_dim_evaluador
oficina
cod_auditor
Create Join
Join(s):
`master_imf`.`h_resultados`.id_dim_tiempo - INNER JOIN - `master_imf`.`dim_tiempo_full
`master_imf`.`h_resultados`.id_dim_ubicacion - INNER JOIN - `master_imf`.`dim_ubicacior
`master_imf`.`h_resultados`.id_dim_cuestionario - INNER JOIN - `master_imf`.`dim_cuesti
`master_imf`.`h_resultados`.id_dim_evaluador - INNER JOIN - `master_imf`.`dim_evaluado
Delete Join
< Back
Next >
Finish
Cancel

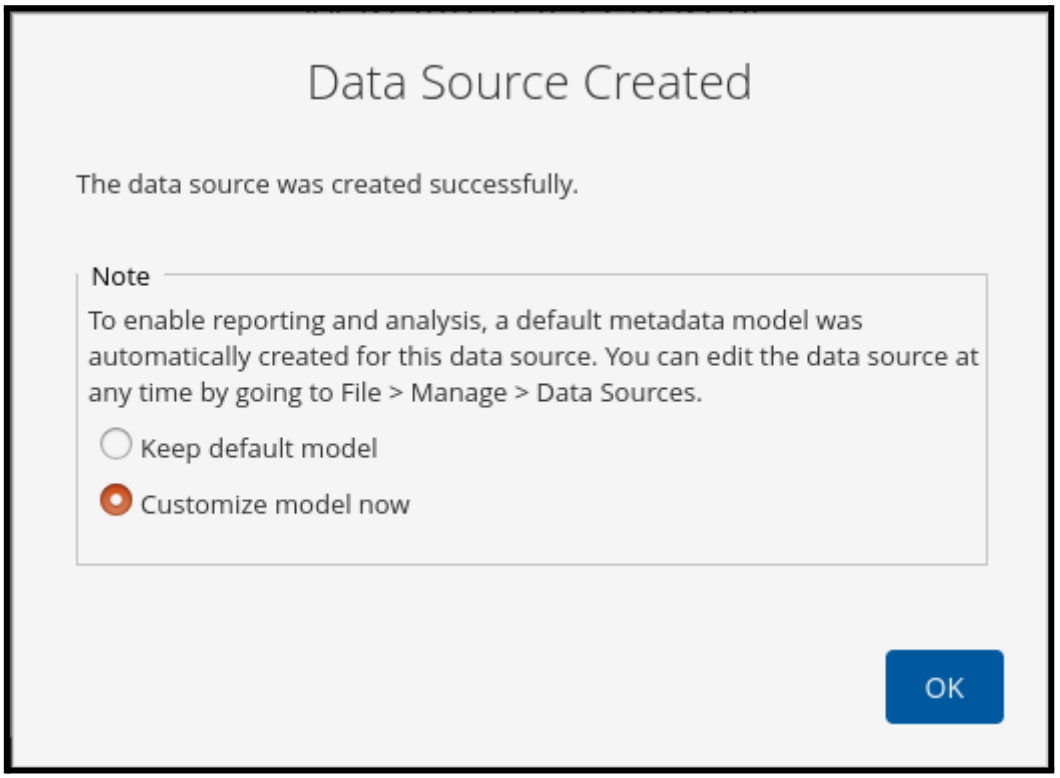
Data Source Created
The data source was created successfully.
Note
To enable reporting and analysis, a default metadata model was automatically created for this data source. You can edit the data source at any time by going to File > Manage > Data Sources.
Keep default model
Customize model now
OK

4. **Editamos el modelo:**

   a. Clear Model.

   b. Medidas:

      - **Resultado:** Average de Resultado.
      - **Número Cuestionarios:** Count de id_h_resultados.
      - **Resultado Máximo:** Minimum de Resultado.
      - **Resultado Mínimo:** Maximum de Resultado.

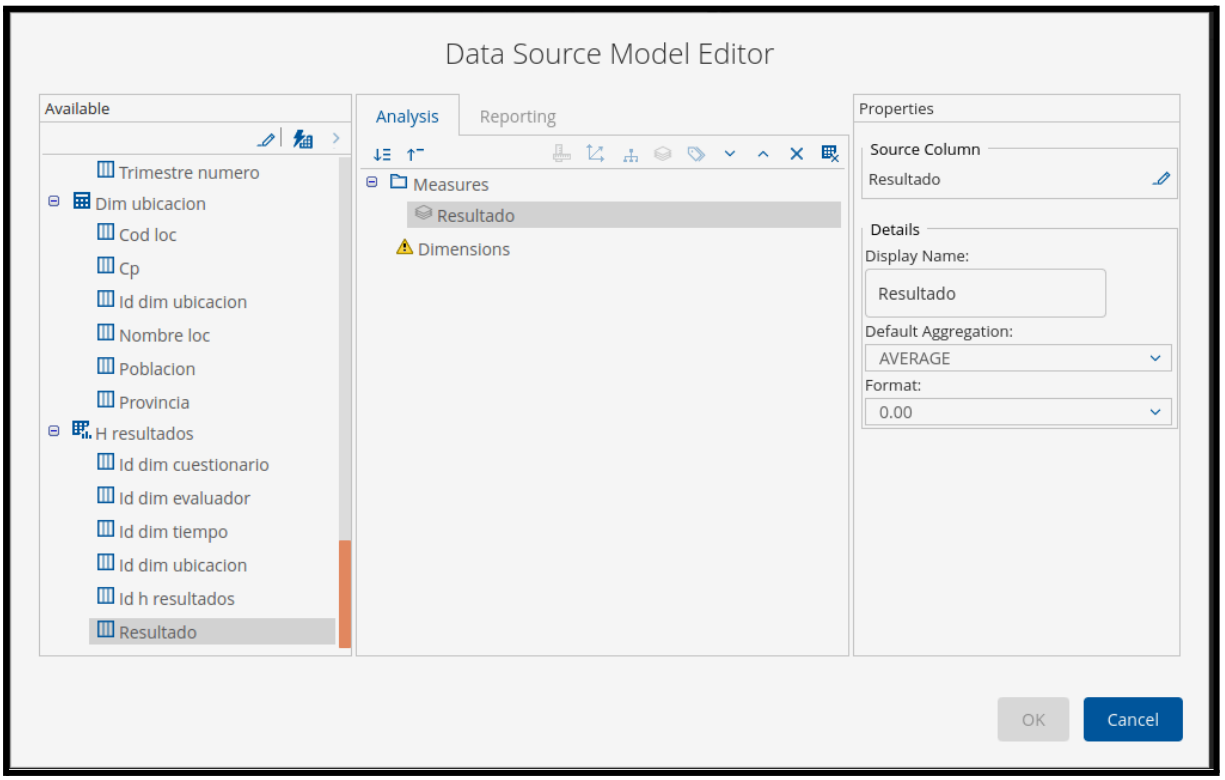

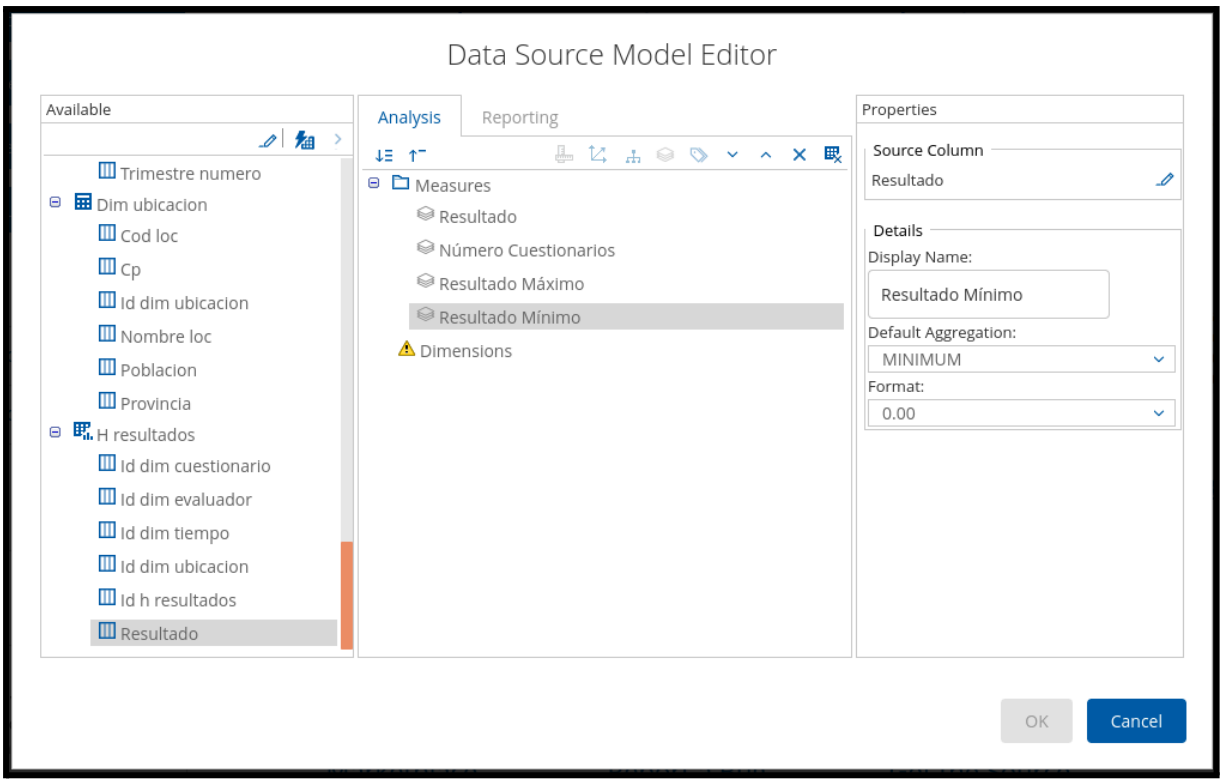

c. **Dimensiones:**

- Dimensión Tiempo:
  - **Fecha**
  - **Año**
  - **Trimestre**
  - **Mes**
  - **Día**
- Dimensión Ubicación:
  - **Provincia**
  - **Población**
  - **CP**
  - **Nombre Localización**
  - **Código Localización**

- Dimensión Cuestionario:
    - **Código Proyecto**
    - **Título Cuestionario**
    - **ID Evaluación**
- Dimensión Evaluador:
    - **Oficina**
    - **Código Auditor**

Por supuesto, aunque no lo especifique, para cada campo hay que seleccionar los tipos y formatos correctos.

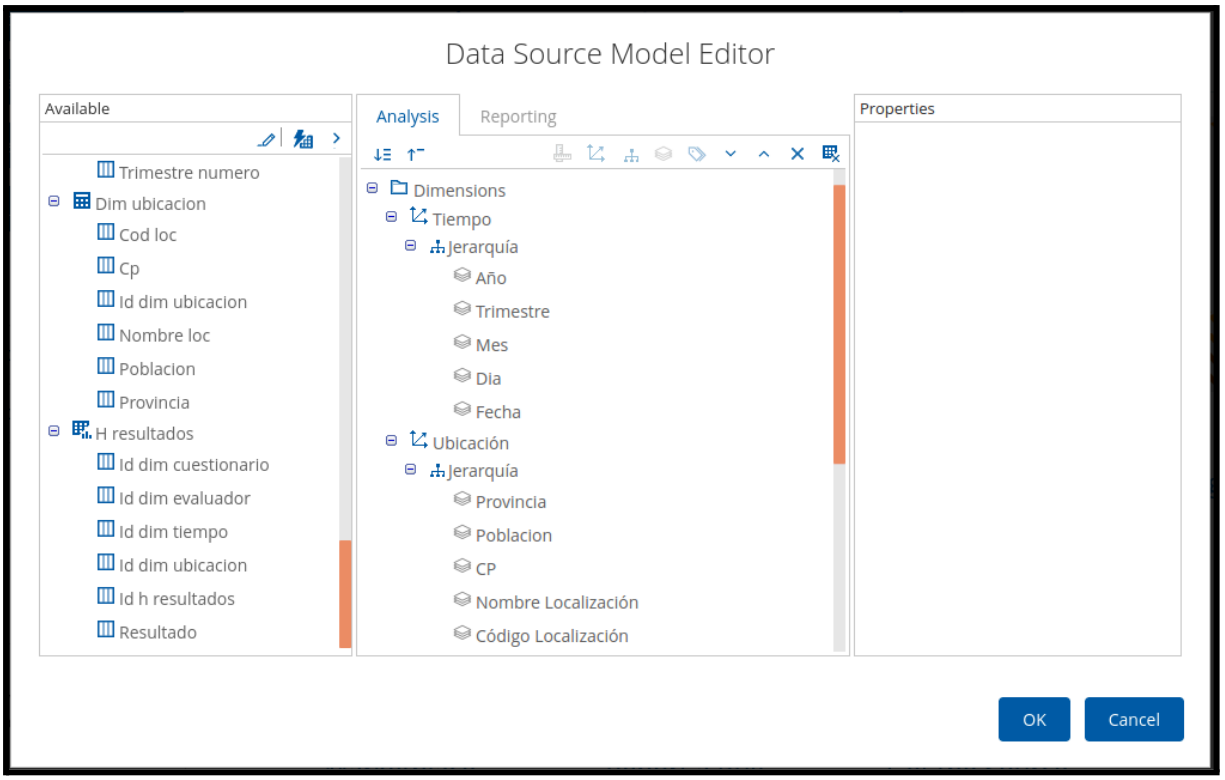

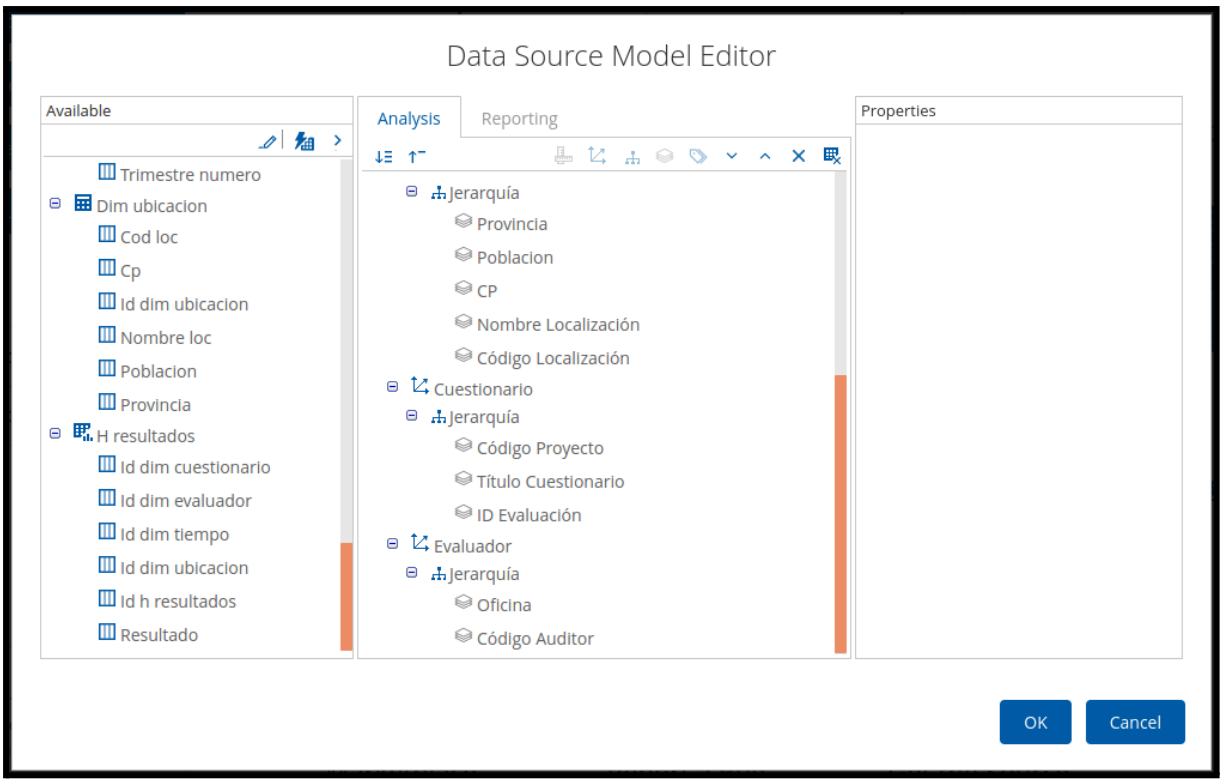

12. Análisis de modelo. Se solicita realizar, al menos, un análisis haciendo uso de un modelo multidimensional que refleje alguna situación relevante de ser explicada y comentada. Para ello, se hará uso de los visores OLAP disponibles en la máquina virtual.

En el entorno proporcionado, la herramienta Pentaho Analyzer no se encuentra disponible o habilitada, por lo que no fue posible utilizarla para la visualización del modelo multidimensional.

Por este motivo, se empleó Saiku Analytics, herramienta incluida en Pentaho Server que permite la explotación de modelos OLAP creados mediante el Data Source Wizard, ofreciendo funcionalidades equivalentes de análisis y visualización.

Resultado (promedio) por año:

Año	Resultado
1995	0,87
2013	0,89
2014	0,80

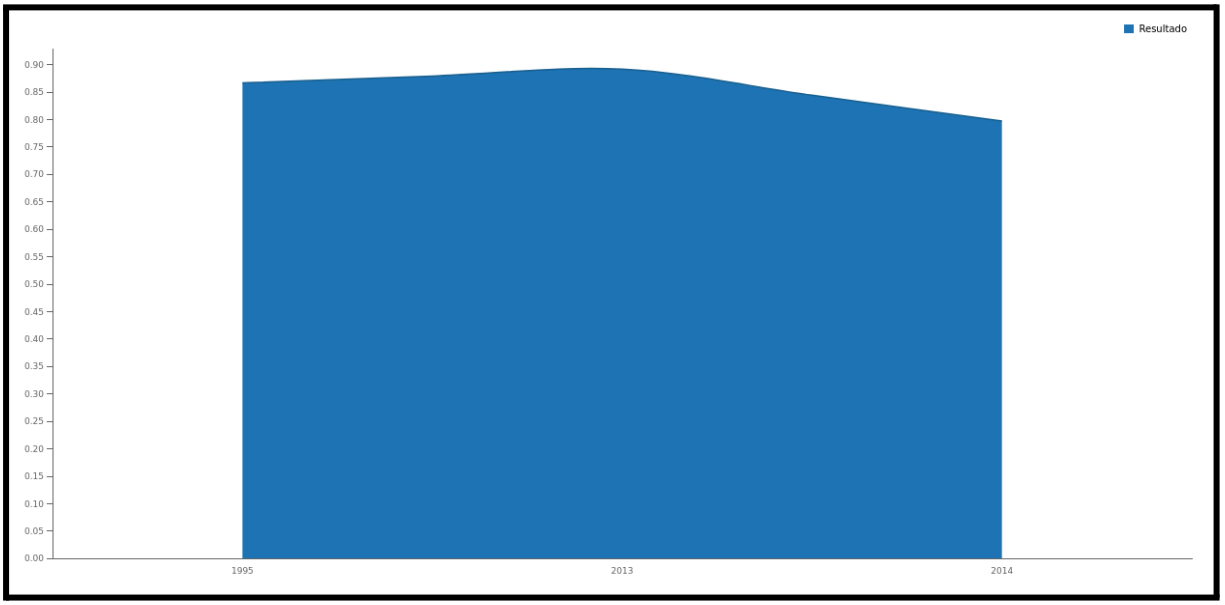

Resultado (promedio) por provincia:

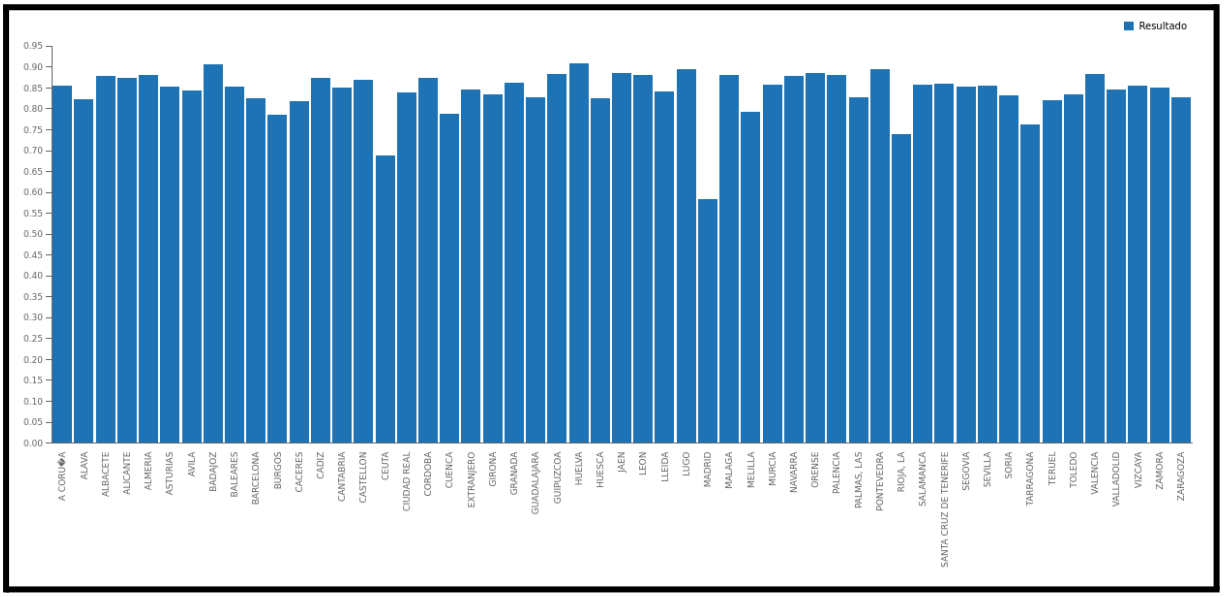

Badajoz y Huelva son las provincias con un promedio más alto, y Ceuta y Madrid son las provincias con un promedio más bajo.

Resultado (promedio) por año (1995):

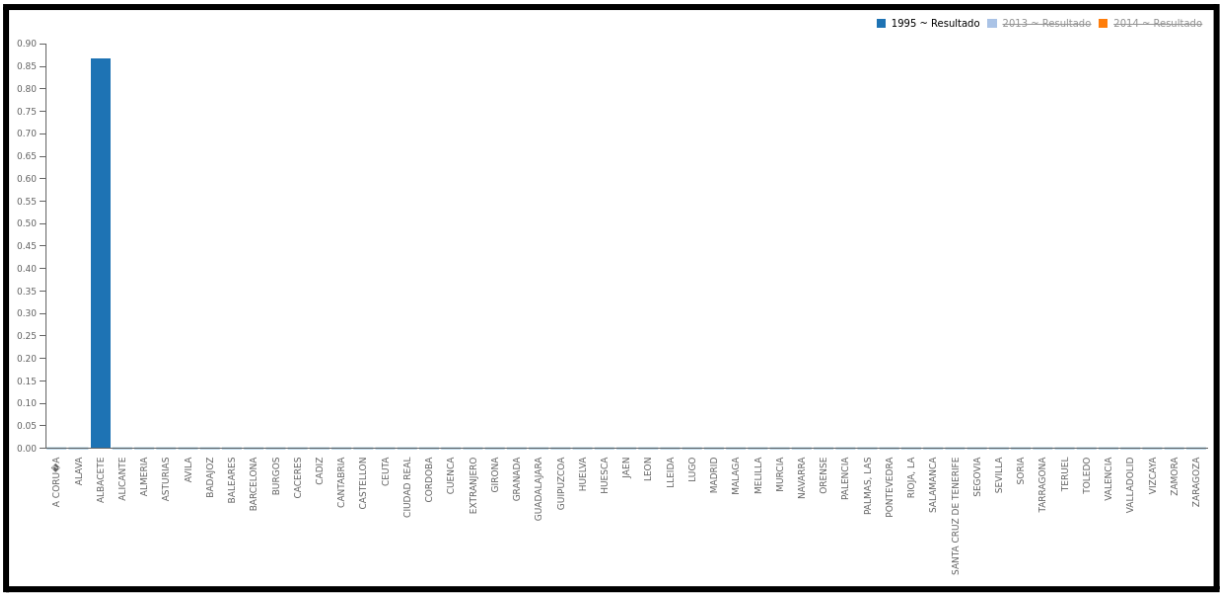

La única encuesta registrada en 1995 se realizó en la provincia de Albacete.

Resultado (promedio) por año (2013):

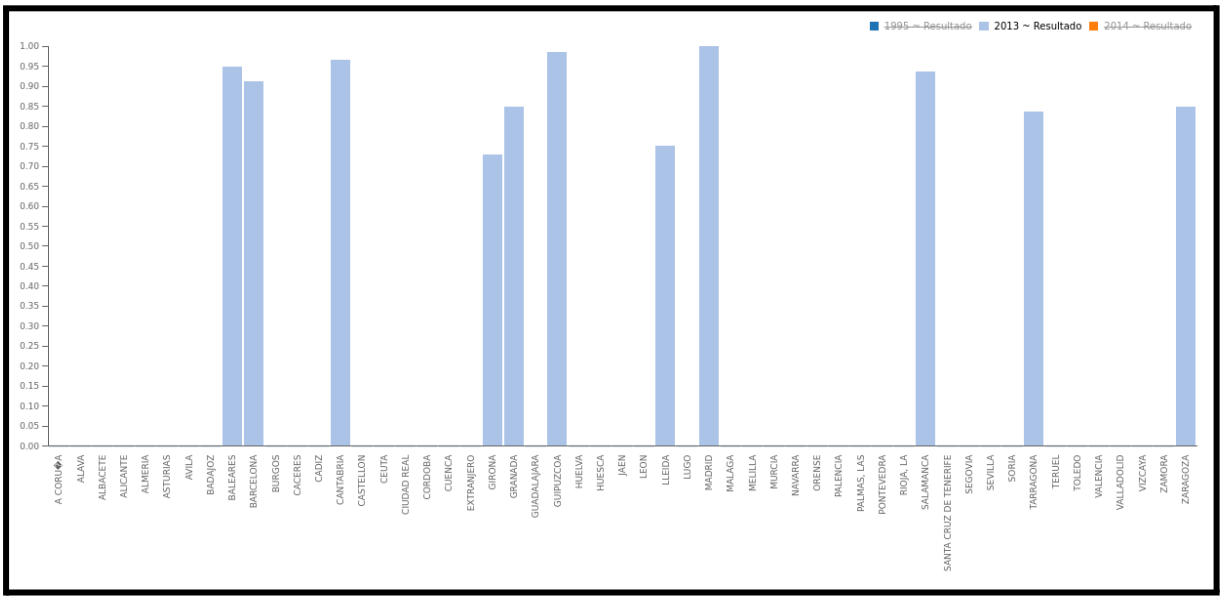

Resultado (promedio) por año (2014):

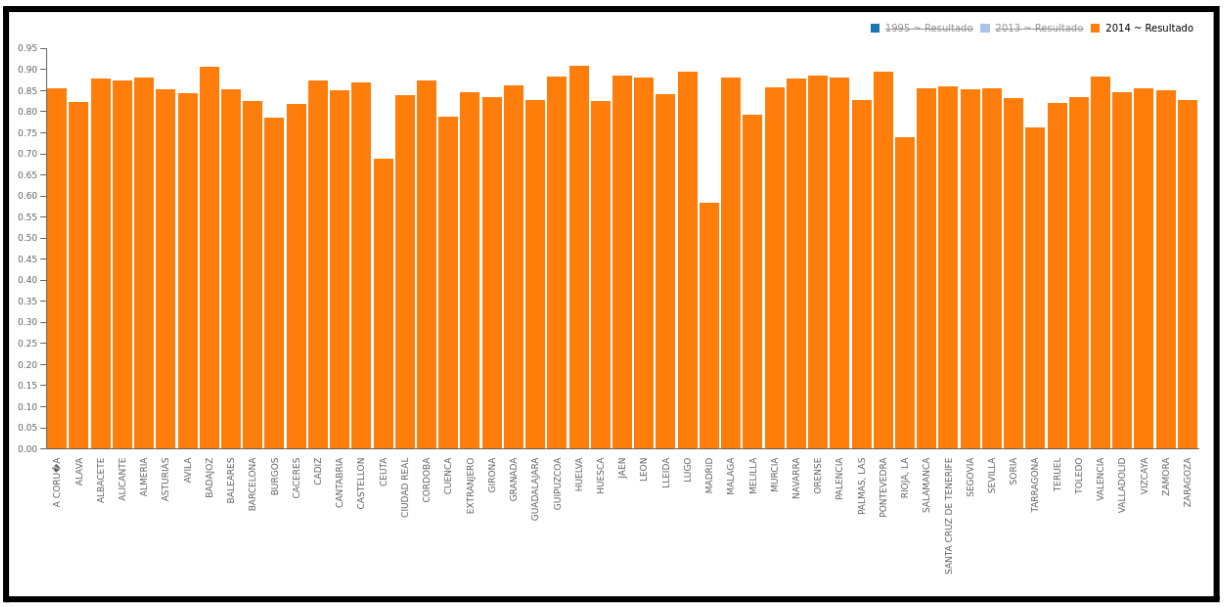

Número Cuestionarios por año:

Año	Número Cuestionarios
1995	1
2013	18
2014	32777

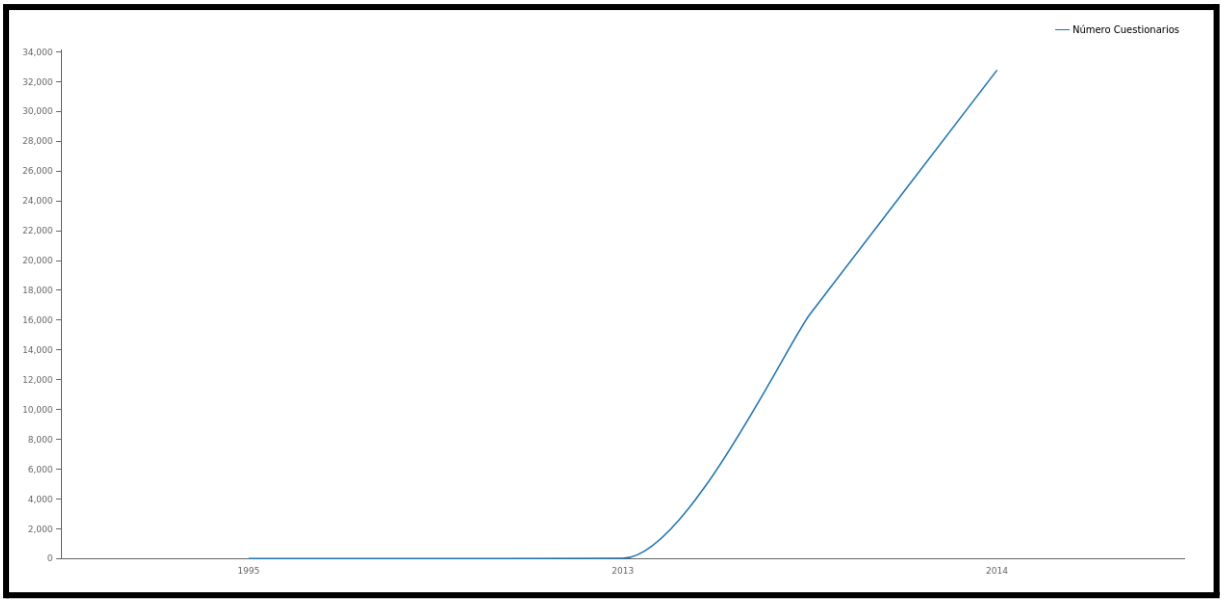

La inmensa mayoría de encuestas fueron realizadas en 2014.

Número Cuestionarios por Provincia:

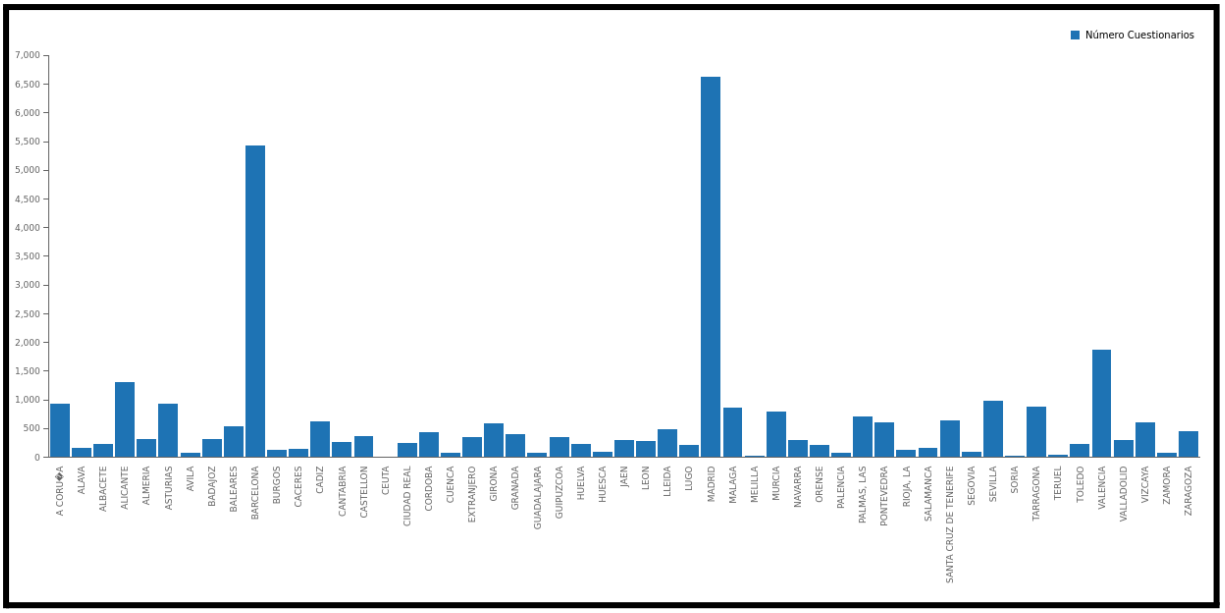

Madrid y Barcelona son con diferencia las provincias donde se han realizado un mayor número de encuestas. Esto por supuesto corresponde con los índices de población y desarrollo de estas dos ciudades.

Número Cuestionarios por Año en Granada:

	GRANADA
Año	Número Cuestionarios
1995	-
2013	3
2014	394

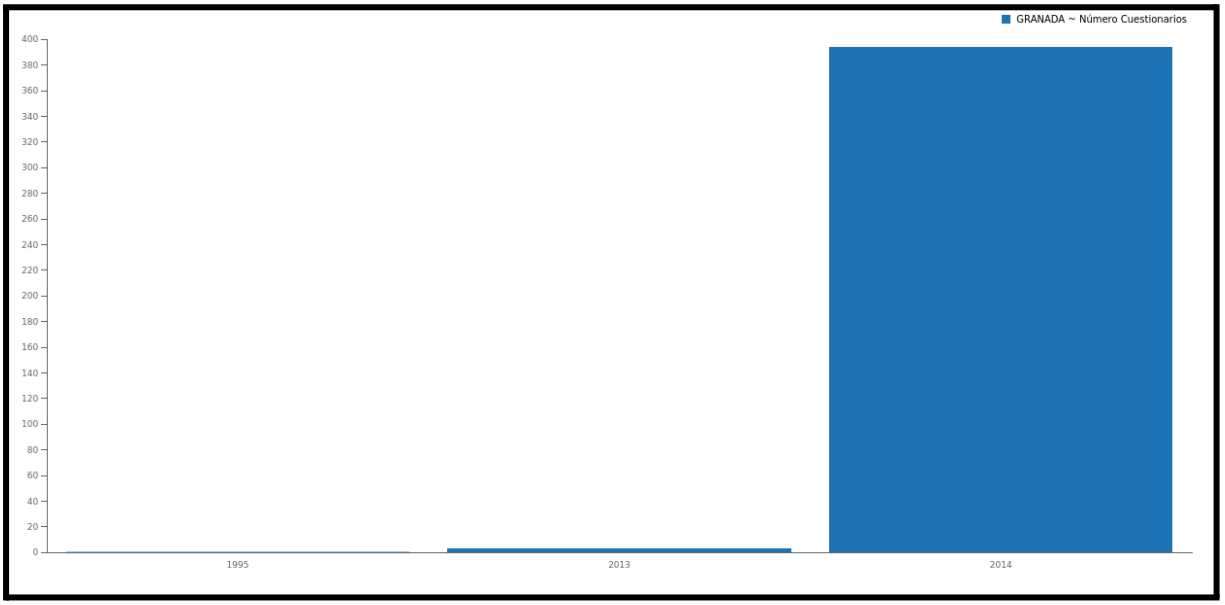

Número Cuestionarios por Año en Madrid:

	MADRID
Año	Número Cuestionarios
1995	-
2013	1
2014	6623

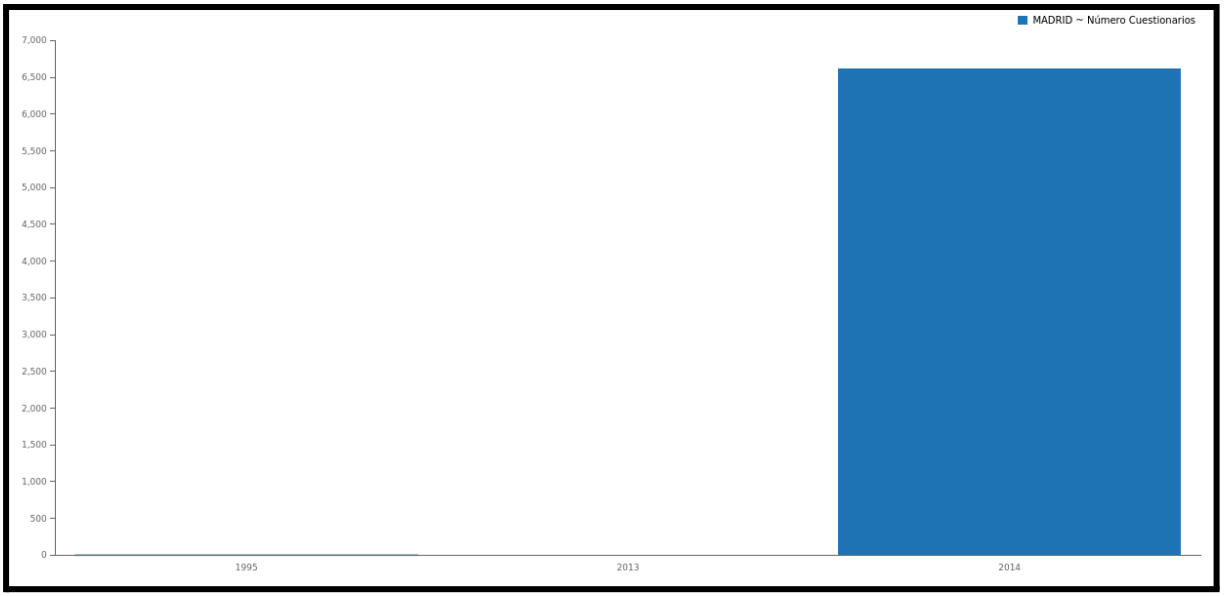

Resultado (promedio) por Año en Madrid:

	MADRID
Año	Resultado
1995	-
2013	1,00
2014	0,58

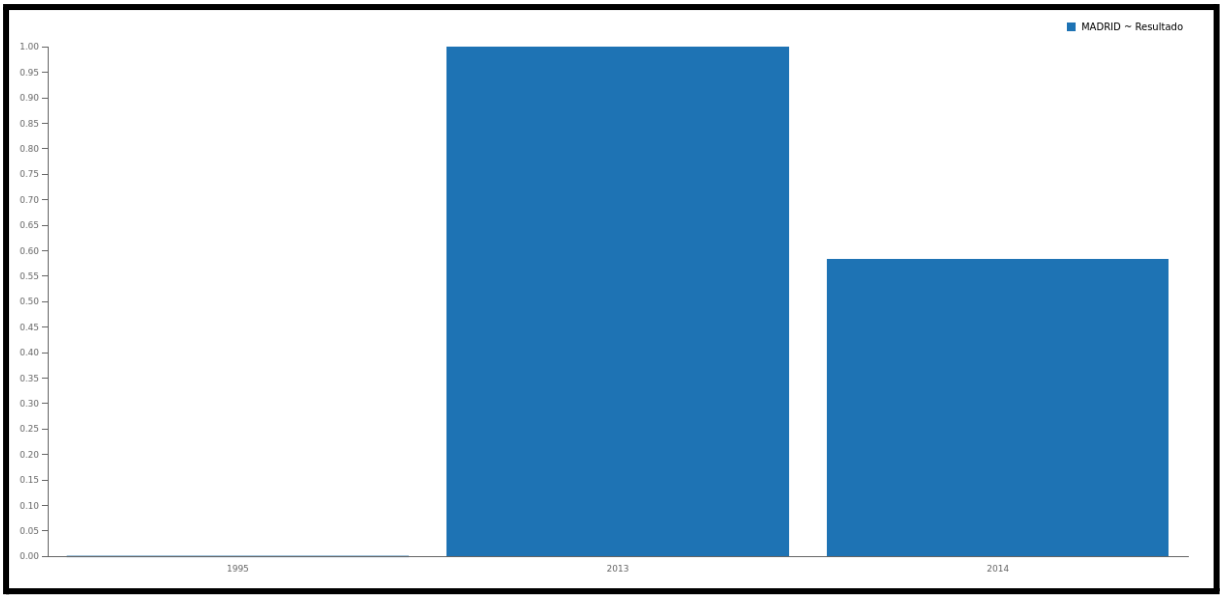

El resultado promedio por año en Madrid claramente es más alto en el año 2013 debido a que ese promedio se basa únicamente en una encuesta que fue calificada con un 1 (la puntuación máxima), y, sin embargo, en 2014 el promedio se basa en más de 6000 encuestas distintas.